

作品编号： CACR20253B9RD3

作品类别：

☐ 软件设计 ☐ 硬件制作 ☐ 工程实践

☐ 密码技术应用 ☒ 其它



2025 年第十届全国密码技术竞赛作品设计报告

作品题目： 密态向量近邻检索算法设计与实现

2025 年 10 月 23 日

中国密码学会

基本信息表	
编号：	CACR20253B9RD3
作品题目：	密态向量近邻检索算法设计与实现
作品类别：	☐ 软件设计 ☐ 硬件制作 ☐ 工程实践 ☐ 密码技术应用 ☒ 其它
作品内容摘要：	在智慧医疗场景中，医学图像、文本病历与生理音频等多模态数据高度敏感，传统明文向量检索易暴露病情方向与访问路径，难以满足医疗隐私要求。本项目提出面向智慧医学的四层密态多模态近邻检索系统，在查询全程加密、访问模式隐藏的前提下，实现对图像、文本与音频的相似病例检索，有效解决“可用检索”与“强隐私保护”之间的长期矛盾。 系统采用前端加密、索引粗排、同态精排与安全网关协同的四层架构：前端在本地生成多模态医学嵌入并以 CKKS 加密，实现端侧隐私保护；索引与存储层融合 K-Means 聚类、IVF 倒排与 PQ 压缩，将百万级向量检索的复杂度由 $O(N)$ 降至 $O(\sqrt{N})$，保证系统在规模扩张下仍具高可用性；同态精排层利用 CKKS 与 BSGS 多对角打包实现密态内积计算；安全网关通过伪簇混合、恒定长度返回与路径混淆机制，有效防御访问模式分析和侧信道推断攻击。 在此架构下，系统在三类医学模态上均实现约 3.0–3.2 秒的端到端密态检索延迟，在严格隐私约束下仍能返回方向一致的相似病例结果，满足智慧医疗中“隐私优先、可用为辅”的实际需求。本项目构建了国内少有的可工程化落地的全密态多模态医学检索原型，兼具隐私保护性、可扩展性与工程可复现性，可应用于智能影像分析、临床决策支持、医学知识检索与医疗数据安全等智慧医疗场景。
关键词：	同态加密 密态向量近邻检索 倒排索引与乘积量化 伪查询

目录

1	作品概述	1
1.1	研究背景	1
1.2	研究动机	1
1.3	作品架构	2
1.3.1	双阶段检索架构设计	2
1.4	技术路径	4
1.5	创新优势	6
1.5.1	分层混合检索架构	6
1.5.2	工程化同态计算优化	6
1.5.3	全链路隐私保护体系	7
2	系统设计	8
2.1	系统总架构	8
2.2	技术栈	9
2.3	系统原理介绍	10
2.3.1	K-means 聚类原理	10
2.3.2	倒排文件与乘积量化原理	11
2.3.3	CKKS 算法下的同态内积原理	13
2.3.4	数值与复杂度基础 RNS 与 NTT 管线	14
2.3.5	假查询生成与调度	15
2.3.6	模型版本与完整性保护安全散列机制	16
2.3.7	并行化计算架构 CPU 多线程优化	17
2.4	系统功能模块设计	17
2.4.1	系统各模块功能	17
2.4.2	主要功能模块	18
2.5	系统使用流程	19
3	系统实现	22
3.1	离线索引与压缩 (IVF + PQ) 模块	24
3.2	客户端 (嵌入 / 选簇 / 加密 / 解密) 模块	27
3.3	服务器 (IVF 粗筛 + CKKS 精排) 模块	29
3.4	同态计算与数值 (CKKS + RNS/NTT) 模块	31
3.5	访问模式隐藏 (假查询 + 调度) 模块	33
3.6	元数据与一致性 (协议一致 / 结果完整 / 多模态) 模块	35

4	系统测试与结果	38
4.1	实现环境与参数配置	39
4.2	实现结果	40
4.3	测试方案	43
4.3.1	加密与计算性能测试	43
4.3.2	安全与隐私保护测试	43
4.4	性能测试	44
4.4.1	资源占用分析	44
4.5	并发计算性能测试	45
4.6	与其它方案计算性能对比	47
4.7	隐私性对比分析	48
5	安全性分析	49
5.1	查询隐私性	50
5.2	数据机密性	50
5.3	侧信道防护	50
5.4	数据泄露防护	50
5.5	一致响应性	50
6	应用前景	51
6.1	核心应用场景：智慧医疗领域的革命性突破	51
6.1.1	跨机构科研协作新模式	51
6.1.2	临床诊疗智能辅助系统	52
6.1.3	医疗 AI 的安全基石与联邦学习增强	52
6.1.4	药物研发与临床试验优化	52
6.1.5	公共卫生与流行病监测	53
6.2	其他重要应用领域	53
6.2.1	金融科技：合规风控新范式	53
6.2.2	司法政务：数据安全共享新路径	54
6.2.3	智能推荐与搜索引擎增强	54
6.2.4	物联网与边缘计算安全	54
6.3	技术生态构建与标准化推进	55
6.3.1	隐私计算平台集成	55
6.3.2	技术标准与产业生态	55
7	总结展望	56
7.1	系统实现成果概述	56
7.2	性能评估与优化成效	56

7.3	安全机制与隐私保护分析	56
7.4	技术创新性与应用价值	57
7.5	实际应用场景拓展	57
7.6	未来研究方向与发展路径	57
7.7	产业化推广策略	58

1 作品概述

1.1 研究背景

近年来，随着向量检索技术在医疗健康、智能诊断、医学影像管理等领域的广泛应用，其潜在的隐私风险逐渐引起研究者的高度关注。一个具有代表性的隐私事件来自多伦多大学的最新研究^[1]：研究团队发现，**76.3%** 的医学期刊病例照片可以被 **Google Images** 直接反向检索出来。这些图片既未附带患者姓名，也未主动发布在公开平台，但攻击者仍能够通过检索系统的访问行为、路径关联以及图像语义相似度分析，将患者身份与病情信息“拼接”出来。这一结果表明：隐私泄露不一定来自黑客攻击，而可能直接源自检索系统本身的工作模式——查询行为即隐私暴露入口。

结合医疗系统普遍采用的“明文向量检索”流程，其隐私威胁可归纳为以下四类：

向量内容是否可以明文存储？医学影像、诊断文本和生理音频的 embedding 本身包含丰富语义信息，一旦以明文形式存储，在服务器遭受入侵或越权访问时会直接暴露病情隐私。查询向量是否自带隐私特征？医生上传的查询 embedding 通常对应特定病灶或症状，其明文传输会暴露患者健康状态与医生的诊疗意图。明文向量计算是否符合监管要求？在 GDPR、HIPAA 等法规约束下，未加密处理医疗语义向量正逐渐被视为不可接受的高风险操作。明文向量计算是否符合监管要求？在 GDPR、HIPAA 等法规约束下，未加密处理医疗语义向量正逐渐被视为不可接受的高风险操作。访问模式是否会成为新的泄露通道？即使向量数据被加密，攻击者仍可通过分析簇访问记录、Top- k 排序行为、响应时间差异等侧信道信息推断敏感医疗信息^[2-3]。

这些问题表明，相比一般互联网应用，医疗场景中的向量检索面临更高的隐私风险：向量内容会暴露隐私、查询动作会暴露隐私、访问模式也会暴露隐私。近年来多起现实攻击事件（如病情推断、患者二次重识别、影像检索系统被动泄露等）进一步验证了这一风险。与此同时，现代医疗 AI 系统呈现明显的多模态趋势：临床检索系统同时处理医学影像、结构化病历文本、语音报告和监护信号等异构数据。多模态的关联性使得攻击者能够通过跨模态推断获得更高精度的隐私信息，而异构性则提高了统一隐私保护方案设计的难度。在此背景下，如何在保持医学检索效率与准确性的同时，为向量检索提供端到端、形式化、工程可部署的隐私保护能力，成为当前亟待解决的重要科研问题。

1.2 研究动机

尽管学术界与工业界已经提出了大量隐私保护向量检索方法，但在隐私性、效率、精度和工程可落地性之间依然难以取得兼顾的平衡。基于密码学的技术路线通常被认为是最具安全性的方案，包括 CKKS 等近似同态加密系统^[4]、全同态加密 (FHE)^[5]、PIR 协议^[6] 等，它们允许在密文上直接进行向量内积等计算，从根本上避免明文泄露。然而，这类方法在高维向量与百万级数据库场景下的计算开销极其庞大，且无法利用 ANN 结构进行亚线性检索，使得查询延迟往往达到秒级甚至分钟级^[2]，难以满足医疗、金融等

对实时性要求极高的行业需求。

相较之下，基于数据扰动与空间变换的方法部署成本低、计算开销小，包括高斯噪声扰动、随机投影、局部敏感哈希等策略。然而，其隐私保证依赖关于攻击者能力的假设，不具有严格的形式化安全性。在高维语义空间中，已有研究表明此类扰动很容易被逆向恢复攻击击穿，攻击者能够以较高精度重构原始语义向量^[7]，并且噪声的存在会显著降低医学检索场景中的召回率，难以用于需要高准确度的医疗诊断辅助系统。

另一类方案从系统架构层面增强隐私保护，包括安全多方计算（MPC）^[8]、联邦式向量检索^[9]、以及基于 TEE 的可信执行环境（如 Intel SGX）。这些方案通常在理论上能够减少单点隐私泄露风险，但在实际部署中面临显著挑战：MPC 与联邦式架构的通信开销会随着参与方数量快速增长，导致难以在百万级向量库场景中维持稳定的实时响应；TEE 则面临侧信道攻击^[3]、供应链依赖、硬件成本高等工程风险，限制了其在医疗等行业的规模化应用。

总体而言，现有技术路线都无法同时满足医疗等隐私敏感行业的三项关键要求：其一，需要保障查询向量、数据库向量以及访问模式的全面隐私，抵御明文泄露、语义反推与侧信道攻击；其二，需要在百万级向量库中保持亚秒级响应，满足临床检索的实时性需求；其三，需要实现接近明文 ANN 的检索精度，避免因加密或扰动而造成诊断辅助质量下降。在严苛监管政策（如 GDPR、HIPAA）与多起医疗隐私泄露事件的背景下，这一矛盾愈发尖锐，也构成本研究提出新型密态向量检索方案的核心动机。

1.3 作品架构

本作品提出双阶段密态检索框架：IVF+PQ 粗筛降低候选量，CKKS 同态精排保障隐私与精度，并辅以匿名传输 + 假查询隐藏访问模式、CPU 并行处理与异步调用提升吞吐、BSGS 旋转密钥最小化降低密钥体积与交换成本。该框架的核心思想是通过分层处理策略，在保证强隐私保护的前提下实现高效检索，具体技术路线如图1所示。

1.3.1 双阶段检索架构设计

整体系统采用离线与在线分离的双阶段运行模式，这种设计借鉴了现代大规模检索系统的经典架构^[10]，同时融入了同态加密的隐私保护特性^[4]。

离线阶段（索引构建）：在此阶段，系统首先通过 K-means 聚类算法将高维向量空间划分为多个子空间，构建倒排索引（Inverted File, IVF）结构^[11]。K-means 算法由 MacQueen 于 1967 年首次提出，后经 Lloyd 等人系统化发展^[12]，成为最经典的聚类算法之一。具体而言，对于包含 N 个 d 维向量的数据库，通过 K-means 算法生成 K 个聚类中心，每个向量被分配到距离最近的簇中。随后，采用乘积量化（Product Quantization, PQ）技术对每个簇内的向量进行压缩编码，将原始的 d 维向量空间分解为 m 个子空间，在每个子空间内独立进行量化，显著减少存储开销和内存占用^[11]。

在密码学参数准备方面，系统基于 CKKS 同态加密方案^[4]规划加密参数，包括多项

式次数 N 、模数 q 的选择，以及尺度因子 Δ 的确定。特别地，采用 BSGS (Baby-Step Giant-Step) 策略优化旋转密钥的生成和管理，BSGS 算法最初由 Shanks 于 1971 年提出用于解决离散对数问题，后被广泛应用于同态加密中的旋转操作优化。该策略将原本需要 $O(d)$ 个旋转密钥的情况优化为仅需 $O(\sqrt{d})$ 个，大幅降低了密钥存储和传输开销^[13]。同时，系统在 CPU 端完成数论变换 (NTT) 的预热和常量预计算，为在线阶段的高效同态计算做好准备。

在线阶段 (密态查询)：在线查询处理采用明文选簇与密态精排相结合的策略。客户端首先提取查询向量并进行归一化处理，然后计算查询向量与所有聚类中心的内积，根据相似度得分选取前 T 个最相关的真实簇。为了隐藏真实的访问模式，系统随机选择 $L - T$ 个假簇与真实簇混合，形成查询集合 S ，这种假查询机制有效抵御了基于访问模式的侧信道攻击。

查询向量使用 CKKS 方案加密为密文 ct_q ，通过匿名传输通道与簇集合 S 一同发送至服务器端。服务器接收到查询请求后，对 S 中的每个簇获取其倒排列表中的候选向量，采用对角打包技术将候选向量构造成适合同态计算的明文格式。随后，服务器执行同态内积计算或余弦相似度近似计算，利用 CPU 多线程并行技术同时处理多个旋转、乘法和重缩放操作。

最终，服务器返回加密的相似度打分结果，客户端解密后仅保留真实簇对应的结果，通过 top- k 选择算法得到最终的检索结果。整个过程中，服务器的计算均在密文状态下进行，有效保护了查询隐私和数据隐私。




图 1: 系统总流程——离线“索引构建”，在线“明文选簇 + 密态精排 + 匿名返回”。

1.4 技术路径

本系统在密态向量检索的实现中引入多项核心优化机制，以兼顾精度、性能与安全性。整个技术路线围绕分层处理、同态计算优化、并行架构、密钥管理和隐私增强五个维度展开，形成了完整的密态向量检索解决方案。

首先，采用 IVF（倒排文件索引）+ PQ（乘积量化）分层检索策略^[10-11]，通过 K-means 聚类算法^[12,14]生成聚类中心并建立倒排索引结构。具体实现中，对于包含 N 个 d 维向量的数据库，通过 K-means 算法生成 K 个聚类中心，将整个向量空间划分为 K 个子空间。随后采用乘积量化技术将高维向量分解为 m 个子空间，在每个子空间内独立进行量化编码。这种分层处理策略将检索复杂度从 $O(N)$ 降至 $O(\sqrt{N})$ ，显著降低候选向量读取开销以及显存与内存占用，实现大规模数据库下的快速粗筛。实验表明，在百万级向量库中，IVF+PQ 索引可将候选集规模压缩至原始数据的 1%-5%，同时保持 90% 以上的检索召回率。

其次，在 CKKS 同态精排阶段^[4]，系统将候选向量构造成对角打包明文块，并与加

密查询向量 ct_q 执行旋转与逐槽乘加操作。CKKS 方案支持浮点数的近似同态计算，特别适合向量相似度计算场景。我们采用多项式次数 $N = 8192$ ，初始模数 q 选择为 218 位，支持最多 4 层的乘法深度。在计算过程中，系统实现密态内积或余弦相似度近似计算：

$$\text{sim}(ct_q, \mathbf{v}) \approx \frac{ct_q \cdot \mathbf{v}}{\|ct_q\| \cdot \|\mathbf{v}\|}$$

整个计算过程服务器不可见任何查询明文信息，确保查询隐私不外泄。与传统的线性扫描相比，我们的密态精排仅在粗筛后的候选集上进行，大幅减少了同态计算的开销。

在性能层面，系统引入 CPU 并行处理与异步调用架构，通过多线程模型实现并行任务调度。具体实现采用线程池技术，利用 `std::thread` 启动独立线程处理各个子任务，有效提高并发性与系统吞吐量。在在线阶段，前端与网关之间的请求采用 gRPC 异步调用模式，以非阻塞方式同时发起多个服务交互。系统设计了基于 SIMD（单指令多数据流）的向量化计算框架，充分利用现代 CPU 的 AVX-512 指令集，将同态计算的关键操作（如数论变换 NTT、逐槽乘加等）进行并行化优化，计算性能提升 3-5 倍。

在密钥管理方面，为减少密钥体积与传输负担，系统在 BSGS（婴儿步-巨人步）旋转密钥最小化^[13]方面采用创新策略。传统同态加密方案需要 $O(d)$ 个旋转密钥，对于高维向量（如 $d = 1024$ ）会产生巨大的存储开销。BSGS 策略将旋转操作分解为 baby-step 和 giant-step 两个阶段，将密钥数量从 $O(d)$ 减少到 $O(\sqrt{d})$ 。在 $d = 1024$ 的典型配置下，仅需约 64 个旋转密钥，相比传统方法减少了 94% 的存储开销。系统还实现了按需生成和缓存机制，进一步优化密钥管理效率。

在安全层面，系统设计了匿名与假查询混淆机制，在选簇阶段引入 $L - T$ 个假簇并结合匿名通道与随机调度。具体实现中，客户端在选取前 T 个真实簇的基础上，随机选择 $L - T$ 个假簇构成查询集合 S ，其中 L 为固定值（通常设为 $2T$ ）。这种机制有效隐藏用户的真实访问模式，抵御基于流量分析和时序推理的侧信道攻击^[3]。系统还实现了恒定时间响应机制，确保不同查询的响应时间分布一致，进一步强化时序隐私保护。

最后，系统支持量化与尺度（ Δ -scale）自适应策略^[4]，根据聚类中心与查询内积的数值范围自动设定同态加密的尺度参数。自适应机制通过分析训练数据的数值分布，动态调整 CKKS 方案的尺度因子 Δ ，避免计算过程中的数据溢出和精度损失。具体而言，系统维护一个数值范围监测模块，实时跟踪内积计算中的中间结果，当检测到潜在的溢出风险时自动调整加密参数。这种自适应策略在不同检索模式下都能保持稳定的 Recall 指标表现，Recall@20 的波动范围控制在 $\pm 2\%$ 以内。

此外，系统还集成了多模态统一编码框架^[15]，支持文本、图像、音频等多种模态数据的统一处理。通过模态特定的特征提取器和共享的隐私保护编码器，系统能够为不同模态的数据生成兼容的密态表示，实现跨模态的隐私保护检索。

在工程实现层面，系统采用微服务架构和容器化部署，各组件之间通过定义良好的 API 接口进行通信。系统支持水平扩展，能够根据负载动态调整计算资源。监控系统实时收集性能指标和异常信息，为运维决策提供数据支持。

综上所述，该系列优化在保证安全性的同时有效提升了系统的运算性能与检索精

度，构成了密态近邻检索系统的核心工程支撑。实验结果表明，在百万级向量库上，系统实现了亚秒级的检索延迟，同时保持了与明文检索相当的精度水平，为隐私保护向量检索的实际部署提供了可行的技术路径。

1.5 创新优势

本研究的创新主要集中在三个层面：分层混合检索架构、同态计算的工程化加速优化，以及覆盖向量内容、查询行为与访问模式的全链路隐私保护体系。这三项创新并非相互独立，而是从系统结构、底层算子到协议级行为共同构筑起一套真正可落地、可扩展并满足医疗场景严格隐私要求的密态向量检索系统。相比传统方案仅在“算法层面”或“通信层面”局部优化，我们从架构、算子和隐私协议三个维度提出系统性突破，使得密态检索首次在百万级向量库中达到可部署的实时能力。此外，现实医疗系统中 embedding 泄露已被证明能够暴露患者隐私，这一问题也进一步凸显了本系统的必要性^[1]。

1.5.1 分层混合检索架构

传统密态检索经常陷入“明文 ANN 高效但泄露严重，全密态检索安全但延迟过高”的结构性困境。针对这一核心矛盾，我们提出了分层混合检索 (Hybrid Layered Retrieval) 架构，将倒排召回的高效性与 CKKS 的强隐私性^[4] 以“分层—分阶段”的方式深度融合。

离线阶段，我们基于 K-means 聚类构建倒排文件 (IVF)，将向量空间划分为 K 个紧致区域，再使用乘积量化 (PQ) 对每簇数据进行残差压缩，这一结构不仅带来高效紧凑的索引组织，也构成了系统后续粗筛阶段的核心基础。IVF 与 PQ 已在大规模相似度检索中被证明具有卓越性能^[10-11]。在线阶段，系统首先在明文侧快速利用 IVF+PQ 检索出仅占 1%–5% 的候选向量集合；随后将这一候选集构造成对角化明文块，与加密查询向量 ct_q 在 CKKS 密态域中执行高精度内积精排。整个在线路径中，查询向量始终保持密态，服务器无法获取任何语义信息。

该架构有效突破了密态检索的传统性能瓶颈——在百万级向量库上，我们实现了约 1.2 秒的 P95 延迟，而 Recall@20 达到明文基线的 97%。这种“明文粗筛 + 密态精排”的分层设计首次证明了密态向量检索不仅可以高效运行，而且可以在真实规模下具备工程可用性，从而解决了行业长期认为“密态检索不可能做到可用规模”的技术难题。

1.5.2 工程化同态计算优化

同态计算是密态检索的核心瓶颈，其性能直接决定系统能否用于真实场景。本系统在算法结构、指令级优化和并行调度三个层面进行了系统性工程优化，使 CKKS 由“理论可用”真正迈向“工程可部署”。首先，系统采用 4096-slot SIMD 批处理机制，将批量向量相似度计算映射到大规模槽位并行执行，使一次同态矩阵乘法即可完成多个候选

向量的点积。同时结合多核调度与向量化（AVX-512）优化，对 NTT、模乘、逐槽乘加等核心操作进行深度流水线化，使单轮密态运算的吞吐显著提升。

其次，我们基于 BSGS (Baby-Step Giant-Step) 优化策略^[13] 减少旋转密钥数量，将同态旋转操作复杂度从 $O(d)$ 降为 $O(\sqrt{d})$ 。在 1024 维向量场景中，无需再维护传统的 1023 个旋转密钥，而只需约 64 个即可完成所有必要旋转，使密钥存储降低 94%，密钥下载与调度成本也大幅减少。这使 CKKS “密钥管理复杂度” 首次下降到可接受范围。

同时，系统使用异步流水线对密态点积任务进行拆分、调度与重叠执行，使 CPU 利用率最大化、等待时间最小化。在中低配 CPU 环境下，我们将密态相似度计算的延迟稳定控制在 200–250 ms，使同态计算真正具备“近实时”能力。综合来看，本系统从工程角度解决了同态加密长期以来的可扩展性难题，使其首次具备在百万级数据集上稳定运行的能力。

1.5.3 全链路隐私保护体系

密态检索的隐私威胁并不仅限于向量内容的暴露，访问模式、输出长度、响应时间、数据流结构等也均可能成为攻击者推断用户意图的侧信道，而这些攻击在近期研究中已得到系统性验证^[2-3]。因此，我们设计了一套覆盖数据内容、访问路径、通信结构与时序行为的全链路隐私保护体系，使系统达到医疗场景要求的“全面不可见”标准。

在内容隐私方面，所有查询向量在客户端加密后发送至服务器，服务器全程仅处理密文，无法通过分布信息、梯度变化或相似度趋势推断查询含义。在访问模式隐私方面，系统引入 Top- T 伪簇混淆策略，在真实访问簇外再混入随机假簇，使服务器无法通过观察访问路径判断用户的病灶方向。同时，系统对所有响应包长度进行固定化，并引入随机抖动机制，使延迟分布不具备可推断性，彻底阻断时序分析攻击。在通信隐私方面，使用 TLS 保障加密传输，并使用 HMAC 校验确保抗重放与抗篡改能力，使恶意中间人无法通过流量内容或结构获取任何信息。

这种从向量内容、查询行为到访问路径、返回结构的纵深隐私防护，使系统不仅满足基本的“数据密态要求”，更满足医疗行业高度关注的“行为可推断性”安全标准，避免医生通过查询某类病例而暴露患者病情方向。该体系解决了现有方案普遍忽视的访问模式泄露问题，为医疗密态检索提供真正的端到端隐私保护能力。

总体而言，这三个创新从架构、算子优化到底层系统安全共同构成了一套可落地、可扩展、可在真实医疗场景中稳定运行的密态向量检索系统，使得密态检索首次在效率、精度与隐私三个维度同时达到工程可用水平，突破了行业长期难以解决的三难困境。

2 系统设计

2.1 系统总架构

本系统旨在实现一个高效、安全的密态向量近邻检索平台，保障用户的查询内容和数据库特征的隐私。系统支持多模态数据的加密检索，包括文本、图像、音频等多种数据类型，旨在为大规模数据库（百万级向量）提供隐私保护的高效相似度搜索。在设计上，我们采用了四层架构模型，以确保系统的高效性、隐私保护性和可扩展性。

系统的架构分为以下四个模块：

1. **前端核心模块**：该模块主要负责与用户的交互，包括用户查询的输入、查询结果的展示、集群信息的可视化展示和性能监控面板等。前端通过 React 框架实现，结合 Zustand 进行状态管理，确保前端的交互流畅且高效。前端模块的设计充分考虑了用户体验，使得用户能够通过直观的界面方便地进行查询，并查看相关的检索结果和性能信息。
2. **索引与存储层模块 (Index & Storage)**：该模块负责离线阶段的特征提取与索引库的构建。对嵌入后的数据进行 K-Means 聚类，并使用 FAISS 构建 IVF+PQ 索引，为后续的同态加密计算提供候选向量。该模块充分利用现代向量检索技术，通过高效的索引机制，确保在大规模数据集上进行快速查询。它能够处理百万级别的向量数据，并为计算层提供必要的检索候选。
3. **同态计算层模块 (HE Compute)**：该层负责在密文域中执行向量相似度计算。使用 SEAL 库的 CKKS 算法，通过 RNS/NTT 和 BSGS 等技术优化计算过程，降低旋转次数，提高并行度，进而提升计算效率。此层在加密查询数据的情况下完成相似度计算和排序，确保在保护隐私的前提下，依然能够提供高效的检索性能。
4. **网关与安全层模块 (Gateway & Security)**：该模块负责在线阶段的隐私保护与数据传输的安全性。在传输过程中，通过匿名化处理、MAC 校验、伪查询注入与固定时间窗聚合等技术手段，有效防止时序攻击和查询模式泄露。网关层不仅保证了前端和后端的数据加密传输，还通过安全机制保护整个查询流程中的用户隐私信息。

如图2所示，系统的四层架构通过模块化设计确保了各个功能的独立性与高效性。在此架构中，每一层模块都扮演着重要角色，从前端交互到后端数据存储和加密计算，再到安全数据传输，每个模块的功能和职责都得到了充分的体现。

该四层架构设计确保了系统的高效性与可扩展性。每一层都独立高效地执行其功能，确保系统的模块化和易于扩展。例如，前端模块的设计支持多模态数据输入，后端则提供大规模、高效的数据处理能力。每个模块通过清晰的职责划分，使得系统在实现时能够快速迭代和扩展，同时在保障隐私的前提下提供高效的检索服务。




图 2: 模块交互流程图

2.2 技术栈

本系统为密态向量近邻检索平台，采用前后端分离架构，模块化设计，整体部署于 Ubuntu Linux 操作系统。为了兼顾易用性、安全性与性能，系统各组件基于现代化技术栈进行构建，功能职责明确，通信接口统一，便于扩展与维护。通过这种架构设计，系统能够高效处理大规模数据查询，同时保障用户隐私。

在技术栈方面，本系统采用了多种先进技术，确保其在高效性、隐私保护性和可扩展性方面的平衡。具体技术栈包括：

- 前端技术：
 - **React 18**: 提供响应式用户界面和组件化开发。React 18 引入的并发特性和优化，使得前端界面能够在高并发情况下仍然保持流畅。
 - **Zustand**: 轻量级的状态管理工具，用于高效管理全局状态，避免不必要的渲染，提高前端的性能。
 - **Vite**: 作为构建工具，提供快速的构建与热重载，优化了开发体验，同时保证了前端代码的高效构建与部署。
- 后端技术：

- C++: 用于实现高效的加密算法和检索逻辑，确保大规模数据处理时的高性能计算。
- FAISS: 作为高效的向量检索库，用于快速查询和索引，提供高效的相似度计算。FAISS 库使得处理百万级向量数据时能够提供快速的查询响应。
- gRPC: 用于后端服务之间的高效通信，gRPC 提供了低延迟、高性能的远程调用机制，确保模块间的高效交互。
- 安全性技术：
 - CKKS (Cheon–Kim–Kim–Song, CKKS): 使用同态加密在密文状态下进行计算，确保查询和计算过程中数据的隐私性，避免泄露明文信息。通过同态加密技术，计算过程无需解密即可完成，从而保证了数据在计算过程中的安全性。
 - HMAC (Hash-based Message Authentication Code, HMAC): 对从服务器端返回并需转发到网关的加密查询密文（如 `ct_q`）附加消息认证码，提供完整性与来源认证，防止在传输过程中数据被篡改或窃取。通过 HMAC，确保数据在传输中的安全性。
 - 假查询: 通过在真实查询中插入假查询数据，混淆查询模式与数据访问，增加攻击者分析查询行为的难度，确保用户隐私不被泄露。该技术有效防止了基于查询行为的侧信道攻击。
 - SHA256: 用于对查询数据进行哈希处理，确保数据的完整性，并防止数据在传输过程中被篡改。SHA256 用于验证数据在传输中的一致性和完整性。

本系统的架构与技术栈选择充分考虑了大规模数据检索的高效性、隐私保护的需求以及系统的可扩展性。通过合理的模块划分和技术整合，每个组件的功能都得到了明确的界定，且每个模块之间的接口和通信设计清晰，确保了系统的高效运作和灵活性。

2.3 系统原理介绍

本节旨在阐述密态近邻检索系统的核心实现原理。系统通过融合同态加密 (Homomorphic Encryption, HE) 与高效向量索引技术，构建了一个分层计算架构，确保在全程密文状态下完成向量相似度计算与检索。下文将依次详述同态内积计算、基于聚类的索引优化、访问模式隐藏及并行计算等关键机制的工作原理与协同流程。

2.3.1 K-means 聚类原理

K-means 是一种将样本集划分为 K 个互不重叠簇的聚类方法，其目标是通过最小化类内平方误差 (Within-Cluster Sum of Squares, WCSS) 之和，找到最佳的簇划分和中心。具体而言，K-means 的目标是使每个簇的样本点与其质心的距离之和最小，从而

实现对样本的划分。得到的中心（质心）为各簇样本的算术均值，这些中心对应于一组 Voronoi 区域，其中每个区域包含一个簇的样本点。在大规模数据检索中，K-means 用于将向量空间划分为若干不相交的区域（簇），查询时仅在最相关的簇内进行后续计算，从而提高检索效率。通过使用 K-means 聚类得到的中心（粗索引），可以形成倒排文件（Inverted File, IVF）的 K 个入口^[12]。

在数学上，给定样本集 $\mathcal{X} = \{x_1, \dots, x_N\} \subset \mathbb{R}^d$ 和簇数 K ，K-means 同时优化簇划分 $\{\mathcal{C}_i\}_{i=1}^K$ 和中心 $\{c_i\}_{i=1}^K$ ，以最小化类内平方误差。目标函数如下：

$$\min_{\{c_i\}, \{\mathcal{C}_i\}} \sum_{i=1}^K \sum_{x \in \mathcal{C}_i} \|x - c_i\|_2^2, \quad (1)$$

其中， c_i 表示簇 $\mathcal{C}_i$ 的质心，计算公式为：

$$c_i = \frac{1}{|\mathcal{C}_i|} \sum_{x \in \mathcal{C}_i} x. \quad (2)$$

K-means 的目标是找到最优的簇划分和中心，使得每个簇内的平方误差最小，从而实现对数据的高效划分。最优解将数据空间 $\mathbb{R}^d$ 划分为一组 Voronoi 区域， c_i 为对应簇的几何中心。这些中心即构成 IVF 的粗索引。

K-means 的求解采用经典的 Lloyd 迭代方法，通过“分配—更新”两步交替进行。在“分配”步骤中，样本点被分配到距离其最近的簇中心；在“更新”步骤中，重新计算每个簇的中心，将其设为该簇所有样本点的均值。每次迭代都会在有限划分集合上单调降低目标函数，因而算法最终在有限步内收敛至局部最优解。然而，由于初始中心的选择，K-means 算法可能陷入局部最小值，为此本系统采用了 K-means++ 初始化方法，通过概率采样选择初始中心，以提高初始化的稳定性，减少随机初值带来的不稳定性^[14]。

在 K-means 聚类中，欧氏距离常用于度量样本间的相似性，而在检索阶段，通常希望与余弦相似度对齐。通过对查询和簇中心进行 L_2 归一化，可以将欧氏距离转换为与余弦相似度相关的度量。具体来说，若将查询向量 q 和簇中心 c_i 进行归一化（ $\hat{q} = q/\|q\|_2, \hat{c}_i = c_i/\|c_i\|_2$ ），则有：

$$\|\hat{q} - \hat{c}_i\|_2^2 = 2(1 - \hat{q}^\top \hat{c}_i), \quad (3)$$

因此，选择最近的中心与最大化余弦相似度是等价的。这一等价关系使得 K-means 聚类与基于余弦相似度的检索方法兼容，保证了高效的向量检索和隐私保护。

2.3.2 倒排文件与乘积量化原理

倒排文件与乘积量化（Inverted File, IVF 和 Product Quantization, PQ）是一种结合了倒排文件技术和乘积量化方法的高效索引与压缩技术，旨在提高大规模数据集中的向量检索效率。首先，通过倒排文件（IVF）技术，整个向量空间被划分为多个簇，每个

簇内的数据通过加密计算进行管理。这些簇的中心（质心）由 K-means 聚类算法确定，形成粗索引，能够有效减少需要检索的向量数量。然后，乘积量化（PQ）技术通过将高维向量空间划分为多个子空间，并对每个子空间进行量化，进一步压缩数据的存储和计算开销，降低计算复杂度。两者结合能够在提供高效查询的同时，保持较低的存储成本和较快的计算速度。

(1) IVF 原理

在大规模向量检索中，为避免对整个数据库逐一计算相似度，常通过聚类将向量空间划分为若干局部区域^[10]。K-means 聚类生成的 K 个中心 $\{c_i\}_{i=1}^K$ 可视为空间划分的锚点。任意数据库向量 x 归入最近中心

$$\text{cid}(x) = \arg \min_{1 \leq i \leq K} \|x - c_i\|_2, \quad (4)$$

并在该中心对应的倒排表（posting list）中登记其标识。在查询阶段，向量 q 与所有中心进行距离或内积比较，选出前 T 个最接近的中心：

$$S_{\text{true}}(q) = \text{Top-}T\{\|q - c_i\|_2 \text{ 或 } -q^\top c_i\}_{i=1}^K. \quad (5)$$

系统随后仅在这些被选簇的倒排表内进行更精细的相似度计算，从而显著降低整体计算量。这种“聚类选簇—局部检索”的结构即 IVF 索引。^[10]

(2) PQ 原理^[11]

倒排表中的每个向量仍然是高维的，直接存储与计算代价较大。为此，乘积量化（PQ）将高维向量分块压缩为离散码，在保持近似结构的同时大幅降低存储与比较开销^[11]。首先我们进行分块与训练。将向量维度 d 均分为 M 个子空间， $d = \sum_{m=1}^M d_m$ 。对第 m 个子空间的样本子向量集合训练 K_s 个码字：

$$\mathcal{C}_m = \{c_1^{(m)}, \dots, c_{K_s}^{(m)}\}, \quad c_j^{(m)} \in \mathbb{R}^{d_m}. \quad (6)$$

每个 $\mathcal{C}_m$ 即为一个局部码本（sub-codebook）^[11]。

其次进行编码。向量 x 被拆分为 $x = [x^{(1)}; \dots; x^{(M)}]$ ，其乘积量化码由各子空间的最近码字索引组成：

$$\text{code}(x) = (\kappa_1, \dots, \kappa_M), \quad \kappa_m = \arg \min_{1 \leq j \leq K_s} \|x^{(m)} - c_j^{(m)}\|_2. \quad (7)$$

最后进行近似重构。解码时，用对应的码字近似原始向量：

$$\tilde{x} = [c_{\kappa_1}^{(1)}; \dots; c_{\kappa_M}^{(M)}], \quad x \approx \tilde{x}. \quad (8)$$

通过 PQ 压缩后，数据库中每个向量仅需 $M \log_2 K_s$ 位即可表示，既节约存储，又允许以查表和加法的方式快速估计查询与候选的距离^[11]。与 IVF 结合后，形成“粗筛

分簇 + 精筛量化”的两级加速机制^[10]。

IVF+PQ 的整体检索过程可分为两个阶段^[10-11]。首先，在第一阶段进行粗筛，通过利用聚类中心选取前 T 个最可能包含目标的簇，仅在这些簇的倒排表中进行候选生成。此阶段的主要目的是快速缩小检索范围，减少后续计算的复杂度。接下来，第二阶段进行精排，对于每个候选簇，系统使用其 PQ 近似向量进行相似度估计，并结合更高精度的计算（如密态内积）来进一步提升检索精度，最终得到排序后的检索结果。通过这种两阶段的检索机制，IVF+PQ 能够在保证计算效率的同时，提供高精度的检索结果。

2.3.3 CKKS 算法下的同态内积原理

全同态加密 (Fully Homomorphic Encryption, FHE) 允许在密文上直接进行算术运算，是实现密态计算的关键技术。CKKS 方案是其中一种针对实数或复数向量的同态加密方案，其特点在于支持浮点数的近似计算。该方案的核心流程是将向量 $\mathbf{z} \in \mathbb{R}^{N/2}$ 通过一个预设的缩放因子 Δ (例如 $\Delta = 2^{40}$) 进行放大，然后编码至多项式环 $R_Q = \mathbb{Z}_Q[X]/(X^N + 1)$ 上的明文多项式，最后加密为密文。每个密文可以容纳 $N/2$ 个槽位，这种结构天然支持 SIMD (单指令多数据) 风格的并行处理。在密文状态下，系统能够直接执行加法、乘法以及通过 Galois 自同构实现的槽位旋转操作，待解密并解码 (即除以 Δ) 后，即可获得目标计算结果的近似值^[16]。

在密态近邻检索的具体应用中，核心问题转化为如何安全地计算加密查询向量 ct_q (对应 $q = (q_1, \dots, q_d)$) 与明文数据库向量 $x = (x_1, \dots, x_d)$ 的内积 $\langle q, x \rangle$ 。由于密文槽位结构的特性，直接计算需要将查询向量的每个分量通过循环旋转移至对应位置，再与数据库向量的相应分量相乘并求和。这种朴素方法的计算复杂度为 $O(d)$ ，当维度较高时效率难以接受。为了优化性能，本系统采用了粗粒度-细粒度 (Baby-Step/Giant-Step, BSGS) 算法对计算过程进行重构。具体实现是将维度 d 分解为 $b \times g$ (其中 $b, g \approx O(\sqrt{d})$)，同时将数据库向量 x 预处理为一组结构化的明文对角矩阵 $\{M_{j,k}\}$ 。基于此，内积计算被重新组织为一个双层求和过程：

$$\text{ct}_{\text{score}} = \sum_{k=0}^{g-1} \text{Rotate} \left(\sum_{j=0}^{b-1} (\text{Rotate}(\text{ct}_q, j) \odot M_{j,k}), k \cdot g \right) \quad (9)$$

该过程首先在细粒度层面通过 b 次旋转和乘加操作完成局部块的内积计算，随后在粗粒度层面通过 g 次旋转将各个块的结果对齐并累加，从而将总旋转次数从 $O(d)$ 显著降低至 $O(\sqrt{d})$ ，极大地提升了计算效率。

在同态乘法操作中，缩放因子膨胀与噪声增长是两个必须解决的关键问题。当两个缩放因子均为 Δ 的密文或明文进行乘法运算时，所得结果的缩放因子将膨胀为 Δ^2 。为维持数值计算的稳定性并有效控制噪声水平，CKKS 方案在每次乘法操作后引入了重缩放 (Rescale) 机制：

$$\text{Rescale} : (R_{Q_\ell}, \Delta^2) \longrightarrow (R_{Q_{\ell-1}}, \Delta) \quad (10)$$

该操作在降低模数规模的同时，将缩放因子重新归一化至 Δ ，从而保持后续运算的一致性。通过为整个同态计算链路预先设计合理的模数链与系统的重缩放策略，可以确保最终解密并缩放后的计算结果：

$$\frac{1}{\Delta} \cdot \text{Dec}(\text{ct}_{\text{score}}) \approx \langle q, x \rangle + O(\eta/\Delta) \quad (11)$$

能够以可控的误差项 η 逼近原始明文内积的真实数值。整个同态计算流程的正确执行，依赖于预先部署的 Galois 密钥（用于支持槽位旋转操作）与重线性化密钥（用于维持乘法运算后密文格式的规范性），进而在严格保护数据隐私的前提下，实现高效且安全的密文向量相似度比较^[16]。

2.3.4 数值与复杂度基础 RNS 与 NTT 管线

为支撑 CKKS 同态加密方案在大规模向量检索中的高效运行，其底层依赖于两大核心技术：剩余数系统（Residue Number System, RNS）与数论变换（Number Theoretic Transform, NTT）。RNS 将大整数模数 Q 分解为一组较小的互素模数 q_ℓ ，使得所有多项式系数运算可在这些小模数上并行进行，避免了处理大整数的计算开销^[17]。NTT 则作为快速傅里叶变换（Fast Fourier Transform, FFT）在有限域上的类比，将多项式乘法的时间复杂度从 $O(N^2)$ 显著降低至 $O(N \log N)$ ^[18]。这两项技术共同构成了 CKKS 同态运算的高效计算管线。

具体而言，CKKS 方案在多项式环 $R_Q = \mathbb{Z}_Q[X]/(X^N + 1)$ 上进行运算，其中模数 Q 被精心设计为一组满足 $q_\ell \equiv 1 \pmod{2N}$ 的互素素数乘积：

$$Q = \prod_{\ell=0}^L q_\ell \quad (12)$$

这种分解使得任意多项式系数可以表示为在各小模数 q_ℓ 上的剩余序列，从而实现完全的并行计算^[17]。在同态乘法过程中，运算沿着预设的“模数链”进行：随着计算深度的增加，系统通过重缩放操作逐步丢弃高位模数，既控制了噪声增长，又维持了数值稳定性。

NTT 技术在此架构中扮演着关键角色。对每个 RNS 分量 q_ℓ ，选取 $2N$ 次本原单位根 ω_ℓ ，定义正变换 NTT 与逆变换 INTT。根据卷积定理，多项式乘法 $c = a * b \pmod{X^N + 1}$ 可转化为 NTT 域中的点乘运算：

$$\widehat{c}_k \equiv \widehat{a}_k \cdot \widehat{b}_k \pmod{q_\ell} \quad (13)$$

这一转换将复杂的多项式卷积转化为简单的分量乘法，极大提升了计算效率^[18]。

基于 RNS-NTT 管线，CKKS 的核心运算原语可进行如下复杂度估计（忽略常数项）：

- 加法运算：复杂度 $\tilde{O}(NL)$ ，不改变密文尺度与模数层级。
- 乘法运算：复杂度 $\tilde{O}(NL)$ ，输出尺度按输入尺度相乘增长。
- 重缩放操作：复杂度 $\tilde{O}(NL)$ ，将尺度归一化并降低模数层级。
- 旋转操作：复杂度 $\tilde{O}(NL)$ ，通过 Galois 自同构实现槽位循环移位。
- 重线性化：复杂度 $\tilde{O}(NL)$ ，将三阶密文降回标准二阶形式。

为维持数值计算的稳定性，系统采用统一的尺度管理策略：所有操作数在乘法前需统一尺度；每次乘法后立即执行重缩放，遵循“一乘一降”原则；累加操作要求所有操作数处于同一模数层级。在精心设计的模数链与严格的尺度管理下，深度为 D 的同态计算电路最终输出误差可控制在 $O(D\eta/\Delta)$ 量级，通过选取合适的缩放因子 Δ 与模数链长度，可以保证密文相似度计算结果的可靠性。

2.3.5 假查询生成与调度

在单服务器半诚实威胁模型下，为有效隐藏真实的簇访问模式，系统采用了“匿名汇聚 + 负二项噪声假查询 + 随机调度”的组合隐私保护机制。这里的“单服务器”指所有计算都集中在单个服务器完成，“半诚实”意味着服务器会忠实执行计算协议，但会记录和分析过程中的所有可见信息（如用户访问了哪些数据簇）以试图推断用户隐私。该机制的核心目标是通过混合真实查询与噪声查询、随机化发送时序，将服务器的观测视角限制为带噪声的簇访问直方图，同时保持与后续同态精确排序流程的兼容性^[2]。具体实现分为三个层次阐述如下。

(1) 匿名化与随机时隙调度 (Arrival/Order Obfuscation, AOO)

每个查询不即刻上送，而是在固定长度的时段 (epoch) 内随机抽取秒级时间槽发送。匿名网络 (Anonymity Network, AN) 对同一时间槽的请求进行批量汇聚后再转发，从而抹除到达时间与先后次序，降低时序侧信道 (Timing Side-channel, TSC) 泄漏风险。这一步将“到达时刻、先后顺序”从服务器可见面中剥离，为后续的“按簇计数”视图奠定基础。令一个时段离散为 H 个时间槽；对真实与假查询合并后的列表 Q 先做全排列，再为每条请求均匀采样槽位标签并入队，确保时序特征的完全随机化。该过程可形式化为：

$$\Pi : Q \longrightarrow \{\text{batch at slot } \tau\}, \quad (14)$$

$$\tau \sim \text{Unif}\{1, \dots, H\}. \quad (15)$$

(2) 负二项机制生成假查询 (Negative Binomial Mechanism for Noisy Histogram, NBM)

对每个簇 b ，独立采样该簇的假查询数量：

$$F_b \leftarrow \text{NB}(r, p), \quad (16)$$

将其与该时段内真实查询集合 R 合并并乱序后交由服务器处理。从服务器视角看，整轮等价于”对各簇查询计数的带噪直方图 (Noisy Histogram, NH)”。通过设置负二项分布 (Negative Binomial Distribution, NBD) 参数 p 和 r ，可为系统提供有效的隐私保障。在一个时段内，单客户端所需假查询的期望量与簇总数 C 、单客户端簇访问上界 Δ 、活跃用户数 U 相关，其量级近似为：

$$\tilde{O}\left(\frac{C\Delta}{U}\right), \quad (17)$$

表明活跃用户越多，单个客户端的计算与通信负担越小。

(3) 与同态精排的对接零向量密文与批量打分 (Integration with Homomorphic Fine-Ranking: Zero-vector Ciphertexts and Batch Scoring, IHF-ZCBS)

为避免”返回整个簇明文向量”的响应开销，对真实查询发送新鲜加密的嵌入密文，对假查询则发送零向量的加密（或等分布重随机化密文）。服务器在密态下逐簇计算内积分数，并返回加密分数而非明文嵌入，显著降低响应体积。在该设计下，假查询对密态得分的贡献为零，其作用在于混淆簇访问频次与调度模式，而不影响真实查询的精确排序结果，实现了隐私保护与功能正确性的统一。

复用率高、负载均衡性好和数值稳定性强等优势。通过统一的尺度管理（统一 scale）和严格的”一乘一降”操作序列，确保了同态计算过程中的数值稳定性。在仅依赖 CPU 计算资源的前提下，该架构能够达到接近实时的密态精确排序性能，为大规模向量检索提供了高效可靠的计算基础。

2.3.6 模型版本与完整性保护安全散列机制

为防止索引模型被篡改或客户端使用过期版本，系统在索引与存储侧引入了基于安全散列算法 (Secure Hash Algorithm 256, SHA-256)^[19-20]的完整性保护机制。(1) 版本标识与更新控制

每次模型重新训练后都会生成新的哈希摘要，客户端通过比对本地存储的摘要与服务器发布的最新摘要，能够准确判断当前模型版本是否过期，从而及时触发更新流程，确保始终使用最新的索引模型。

(2) 完整性校验机制

客户端从服务器拉取簇中心文件后，会在本地重新计算其 SHA-256 哈希值，并与服务器下发的基准指纹进行严格比对。若两者不一致，则表明文件在传输或存储过程中可能遭到篡改或损坏，客户端将拒绝使用该文件，从源头保障数据的完整性和可靠性。

(3) 多模态一致性保障

针对多模态检索场景，系统为不同模态的中心文件分配唯一的哈希摘要，这些摘要作为全局模型标识符 (Global Model ID, GMID)，确保客户端与服务器始终在同一模型上下文中协同工作，避免因模型版本不匹配导致的检索结果偏差。

2.3.7 并行化计算架构 CPU 多线程优化

基于候选分数计算彼此独立的特性，系统在中央处理器（Central Processing Unit, CPU）上设计了高效的多线程并行架构。该架构采用固定线程池技术，按照“候选分块 $\times$ BSGS (Baby-Step Giant-Step) 细粒度步”的二维策略进行任务划分，充分利用了计算任务的独立性。同时，系统将剩余数系统（Residue Number System, RNS）质数、数论变换（Number Theoretic Transform, NTT）根、Galois 元等公共常量置于只读缓存中实现多线程共享，显著提升了缓存复用率。

该并行架构具备可并行性强、缓存复用率高、负载均衡性好和数值稳定性强等优势。通过统一的尺度管理（统一 scale）和严格的“一乘一降”操作序列，确保了同态计算过程中的数值稳定性。在仅依赖 CPU 计算资源的前提下，该架构能够达到接近实时的密态精确排序性能，为大规模向量检索提供了高效可靠的计算基础。

2.4 系统功能模块设计

2.4.1 系统各模块功能

本系统围绕密态向量检索系统设计了多个关键功能模块，以保障数据的隐私保护和检索效率。系统的核心模块包括以下四个功能模块：前端核心模块、索引与存储层模块、同态计算层模块、网关与安全层模块。每个功能模块都有其特定的作用，它们共同协作，确保系统高效、安全地执行任务。每个模块的设计目标和具体功能如下：

(1) 前端核心模块

该模块负责与用户进行直接交互，包括用户查询输入、结果展示、集群信息的可视化展示以及性能监控面板的展示等。前端通过 React 框架结合 Zustand 状态管理库来实现高效和流畅的用户体验。该模块不仅支持用户输入查询请求，还能在查询过程中向用户展示实时的查询结果和相关统计信息。前端模块通过简洁直观的界面设计，保证了用户能够快速理解和操作系统，提升了整体的用户体验。

(2) 索引与存储层模块 (Index & Storage)

本模块主要负责数据的索引构建与存储管理。通过 K-Means 聚类算法对数据进行分类，并使用 FAISS 库构建 IVF+PQ 索引。该模块有效地管理和存储海量数据，为后续的计算任务提供高效的查询候选。它采用高效的向量检索机制，不仅可以处理大规模数据集，还能保证在需要快速检索时，能够精准地定位查询数据。

(3) 同态计算层模块 (HE Compute)

此模块负责在加密状态下执行向量相似度的计算。利用 SEAL 库中的 CKKS 算法，配合 RNS/NTT 和 BSGS 技术优化计算过程，显著提升了计算效率。此模块能在保持数据隐私的前提下完成加密数据的计算，确保即使数据处于加密状态，查询仍能高效准确地返回结果。

(4) 网关与安全层模块 (Gateway & Security)

本模块负责保障前后端数据传输过程中的安全性。它通过匿名化处理、MAC 校验、伪查询注入以及时间窗聚合等技术，确保数据在传输过程中的隐私和完整性。此层不仅起到前后端通信的桥梁作用，还通过一系列安全防护措施有效地防止时序攻击和数据泄露，确保用户的隐私信息得到保护。

这些功能模块各自独立、高效地执行其功能，确保系统的模块化设计和易于扩展。在系统架构中，每个模块都有明确的功能定位，通过清晰的职责划分，能够在确保隐私的前提下，提供高效的检索服务。

2.4.2 主要功能模块

本系统的密态向量近邻检索流程涉及多个核心模块，下面对每个模块进行详细的功能说明，确保系统从数据输入到查询输出的全过程高效、安全地进行。

(1) 高效查询与压缩 (IVF + PQ) 模块

该模块负责将输入的查询数据进行压缩并执行高效的检索。具体来说，使用 K-means 聚类算法训练得到的簇中心，根据 FAISS 构建倒排索引 (IVF) 并结合乘积量化 (PQ) 进行压缩，以减少检索时的计算量和存储需求。此模块的设计确保了大规模数据检索的快速响应和高效处理。

(2) 查询 (输入/选择/加密/解密) 模块

该模块负责将用户查询数据进行预处理。首先，通过 L2 归一化对输入的查询进行标准化，并从多个候选簇中选择出最相关的簇，再通过加密技术使用 CKKS 加密查询数据 (ctq)。该模块的目标是优化查询过程，并确保查询数据在计算过程中的隐私保护。

(3) 服务端查询 (IVF 算法 + CKKS 精排) 模块

服务端接收到加密的查询后，首先使用倒排索引 (IVF) 从多个簇中筛选出最相关的数据。然后，通过 CKKS 加密算法在密文域中计算查询与候选数据的相似度，并返回加密后的计算结果。该模块确保查询过程中的高效性与隐私保护。

(4) 同态计算与数据值计算 (CKKS + RNS/NTT) 模块

该模块负责执行同态加密下的计算任务。通过 CKKS 算法结合 RNS/NTT 技术，在加密数据上执行内积计算。这个过程在加密状态下完成，确保了数据的隐私性，且能够高效地利用 CPU 上的多核计算资源。

(5) 访问模式隐蔽 (伪查询 + 调度) 模块

为了进一步增强系统的安全性，该模块通过访问模式的隐蔽性技术来防止查询模式泄露。通过伪查询注入与固定时间窗机制，系统能够避免泄露查询行为，并确保查询结果的隐私性。

(6) 元数据与一致性 (版块/完整性/多模式) 模块

该模块主要负责存储系统的元数据，并确保数据的一致性与完整性。在进行查询时，系统会使用加密的 ID 来映射查询请求，确保数据与检索结果的一致性，并提供高可靠的存储和版本控制能力。

这些功能模块协同工作，共同完成从数据存储到检索的全过程。在前端与后端的配

合下，系统能够在保证隐私保护的同时，实现大规模数据的高效处理和查询响应。每个模块的设计都注重模块化和高效性，确保了系统的可扩展性和安全性，为用户提供快速、准确、隐私保护的检索体验。

2.5 系统使用流程

本系统的使用流程包括用户在前端界面的操作、后端服务的响应，以及数据的处理和返回。以下描述了整个系统从用户查询到结果展示的具体操作步骤：

- 1. 用户查询：用户在前端界面输入查询内容或上传文件。系统支持文本、图像与音频三种查询类型，用户可根据检索需求选择对应模式。




图 3: 用户查询界面

- 2. 结果计算与排序：候选簇确定后，服务端在密文域中执行精排计算，利用同态内积算法评估查询密文与候选向量的相似度。计算结果以密文形式返回，前端仅接收加密分数，不会看到任何中间明文。



图 4: 结果计算与展示界面

3. 解密与展示：前端在接收加密结果后，通过本地私钥执行解密，得到最终的 Top- K 检索结果。同时界面显示相关性能指标，供用户评估检索效果。



图 5: 解密与展示结果界面

4. 后端执行细节与服务联动：整个后端流程由三个核心服务协同完成：索引与存储层、同态计算层和网关编排层。它们共同实现从密文生成、索引检索、密态打分到结果返回的全链路计算。

- 索引服务 (IndexService)：负责加载离线阶段生成的簇心与倒排结构，并执行对角打包 (CreateDiagBlocks)，将特征矩阵映射为多块内存映射文件（如 blk-000000.bin）。通过 mmap 技术支持按需加载与分块访问，显著减少 I/O 开销并实现高并发下的快速数据供给。此外，系统会在启动阶段自动检测可用的内存空间与槽位配置 (slots, blocks)，以保证在同态计算层读取明文素材时具有最优对齐与缓存利用率。整个打包过程的日志输出如图 6 所示。

```
[CreateDiagBlocks] cand=16384 slots=4096 blocks=4 first_path=/home/wen/Desktop/backend/services/index/data/diag_blocks/blk-000000.bin
```

图 6: 索引服务的对角打包 (DiagBlocks) 生成过程

- 同态计算服务 (HeComputeService)：接收来自网关的密文查询，基于 CKKS 同态加密执行密态向量内积计算，输出密文得分。结果记录序列化长度 (serialized_bytes) 并写入 scores_raw_raw 目录，为后续评估提供数据。如图 7 所示，系统在返回阶段输出多轮加密结果 (reply.ct#)，每个密文块均包含多项参数标识（如 polyN、is_ntt、parms_id 等），用于确保同态计算过程的结构一致性与精度稳定性。

```
[HeComputeRpc] RAW dump -> /home/wen/Desktop/backend/ckks/scores_raw_raw (count=
4)
[HeComputeRpc] reply cts=4
[HeComputeRpc] reply.ct#0 size=2 polyN=8192 is_ntt=1 parms_id=(13420828830235061
91,7162084550649654076,10855999249838916620,1321075796840322136)
[HeComputeRpc] reply.ct#0 serialized_bytes=393329
[HeComputeRpc] reply.ct#1 size=2 polyN=8192 is_ntt=1 parms_id=(13420828830235061
91,7162084550649654076,10855999249838916620,1321075796840322136)
[HeComputeRpc] reply.ct#1 serialized_bytes=393329
[HeComputeRpc] reply.ct#2 size=2 polyN=8192 is_ntt=1 parms_id=(13420828830235061
91,7162084550649654076,10855999249838916620,1321075796840322136)
[HeComputeRpc] reply.ct#2 serialized_bytes=393329
[HeComputeRpc] reply.ct#3 size=2 polyN=8192 is_ntt=1 parms_id=(13420828830235061
91,7162084550649654076,10855999249838916620,1321075796840322136)
[HeComputeRpc] reply.ct#3 serialized_bytes=393329
```

图 7: 同态计算服务返回密文得分 (HeComputeRpc)

- 客户端与网关交互：客户端在发起查询前上传评估密钥 (relin 与 galois)，供服务器执行重线性化与旋转操作。随后运行 search_real_ct.py 生成查询密文，并附带 HMAC 元数据 (x-ct-mac, x-ct-nonce, x-ct-ts)。网关在转发密文请求后接收计算结果，将其写入本地路径 (scores_out)，并记录端到端延迟。

```
wen@wen-virtual-machine:~/Desktop/backend/ckks$ python3 upload_evalkeys_v1.py
[EvalKeys] POST http://127.0.0.1:18083/eval-keys
  client_id = gw, key_ver = v1
  galois_b64_len = 44180008, relin_b64_len = 1840732
[EvalKeys] status: 200
[EvalKeys] response: {"msg":"ok","ok":true}
...
wen@wen-virtual-machine:~/Desktop/backend/ckks$ cd ~/Desktop/backend/ckks

HE_CLIENT_ID=gw HE_KEY_VER=v1 \
python3 search_real_ct.py
[*] 读取 ct_q.bin: 329644 bytes
[*] 连接 Gateway: 127.0.0.1:50052
[*] saved /tmp/req.json and /tmp/req.pb
[*] HMAC metadata prepared (x-ct-mac, x-ct-nonce, x-ct-ts)
scores_ciphertexts = 8
pack_shapes        = [(1, 4096), (1, 4096), (1, 4096), (1, 4096), (1, 4096), (1,
4096), (1, 4096), (1, 4096)]
latency_ms(proto)  = 131
latency_ms(client) = 172
saved to: /home/wen/Desktop/backend/ckks/scores_out
first bytes len    = 393330
```

图 8: 客户端上传评估密钥并发起真实查询请求

通过上述三层协作，系统完成从“密文生成 → 索引加载 → 同态打分 → 密文返回 → 解密展示”的完整闭环流程。在单次查询下，系统实现 8 份密文结果返回，兼顾隐私保护与检索性能。

系统的整体流程由前端与后端紧密配合完成，从数据输入到结果展示形成安全高效的闭环。前端提供直观的操作界面，后端以 CKKS 同态加密与多层协同计算为核心，确保数据隐私、安全与性能三者兼得。

3 系统实现

本系统的实现基于隐私保护的高效向量检索框架，核心流程由六个功能模块首尾衔接：离线索引与压缩、查询处理、服务端查询、同态计算与数据值计算、访问模式隐蔽、元数据一致性。各模块在职责内独立运行、在数据面紧密协同，保证从用户发起查询到结果回传的全过程既高效又安全。首先，离线索引与压缩 (IVF + PQ) 在建库阶段完成向量空间划分与压缩：对嵌入后的库向量进行 K-Means 聚类得到簇心，基于 FAISS 构建倒排索引 (IVF) 并训练乘积量化 (PQ) 码本，显著降低召回阶段的计算与存储成本；随后进入查询处理：前端将用户输入 (文本/图像/音频) 编码为特征向量并做 L_2 归一化，客户端据此按簇心打分选取 T 个真簇并在客户端侧混入 $L-T$ 个伪簇形成定长簇列表，准备最小覆盖的旋转键集合，并将标准化查询加密为同态密文 ct_q ；其后由访问模式隐蔽 (网关整形) 接续，网关对客户端已混入伪簇的请求执行统一长度校验、固定时间窗聚合与随机时隙调度，并为需转发的密文 (如 ct_q) 附加 HMAC 以完成完整性与来源校验，形成批量、等长且时序不可区分的转发流；经网关整形后的批查询进入后端触发服务端查询：利用已构建的 IVF 在所给簇内进行近似召回，按 PQ 码本快速估分，从各簇汇总得到规模受控的候选集合 (如前 R 个)，以降低访存与计算开销；继而由同态计算与数据值计算完成密态精排：在 CKKS 方案下对查询密文与候选明文/明文对角块执行密态余弦相似度 (等价内积) RNS/NTT 与 BSGS 多对角打包减少旋转次数、提升并行度，产出分数密文并回传前端；最后由元数据一致性收尾：对批次标识、索引版本、簇/候选映射 (可含簇列表哈希) 进行一致性校验，前端解密分数密文并完成 Top- k 排序与展示，确保同一次查询在不同节点与不同时间窗下得到一致、可复验的输出。由此形成一条流水化协作链路——“离线建库 → 查询标准化与客户端侧伪簇混入 → 网关隐蔽整形与 HMAC 保护 → IVF+PQ 召回 → CKKS 密态精排 → 元数据一致性与结果呈现”，在百万级向量规模下实现高吞吐、低泄露面的密态近邻检索。

基于上述总体实现思路，系统的核心功能进一步被划分为六个紧密衔接的模块。




图 9: 系统六大核心模块及交互流程示意图

如图 9 所示，系统整体被划分为 离线支撑域、服务端域、网关域与客户端域四个功能层：离线支撑域负责索引建库与元数据维护；网关域承担访问模式隐藏与恒定化调度；服务端域执行密态相似度计算与同态打分；客户端域则完成查询生成、加密、解密及结果展示。六个模块间通过加密查询、恒定化请求、分数密文与完整性校验等数据通

道实现闭环交互，构成了一个可运行、可验证且具备隐私保护能力的密态向量近邻检索系统。

下文将依次介绍这六个模块的主要职责、运行流程与实现机制，展示系统从离线建库到加密查询、密态计算与结果解密的完整执行链路。

3.1 离线索引与压缩 (IVF + PQ) 模块

本模块承担系统的离线建库职责，主要目标是构建高效的倒排索引结构与量化压缩机制，为在线检索阶段提供快速、低成本的候选向量召回能力。系统在离线阶段对全部向量样本执行 K-Means 聚类生成簇中心，并在每个簇内部利用乘积量化 (Product Quantization, PQ) 方法进行编码与压缩，从而在保持检索精度的同时显著降低存储体积与后续计算开销。聚类阶段采用 L2 距离作为度量标准，以确保聚类划分的几何一致性，并使用 k-means++ 初始化以减少随机性带来的聚类波动。在训练完成后，系统输出的制品包括簇心文件、倒排表、PQ 码本与压缩索引数据，形成完整的 IVF+PQ 索引结构，为后续在线阶段提供高效的候选向量访问入口。

在在线检索阶段，系统通过对查询向量与预存簇心的距离计算，选取前 T 个最相关的簇作为候选集合，从而将搜索空间从原始百万级向量显著压缩到较小的局部范围。为了保证离线与在线过程中的度量一致性，查询端在输入特征后会执行 L_2 归一化，使其与离线聚类阶段的 L2 空间保持统一；同时，查询打分阶段通过内积分数近似余弦相似度，从而兼顾计算效率与相似性精度。系统在索引构建与查询执行中充分利用多核 CPU 并行能力，通过多线程并行完成大规模 K-Means 聚类与 PQ 编码任务，并在数据输出时采用顺序写入或内存映射 (mmap) 机制，优化磁盘 I/O 性能。

为保证索引数据的长期一致性与可追溯性，系统在所有输出制品（包括簇心、倒排表、PQ 码本及量化索引数据）中嵌入 SHA-256 校验哈希值与版本信息。加载阶段系统会自动验证文件完整性，防止索引错配或版本不符造成的检索异常。通过上述机制，离线索引与压缩模块实现了聚类精度、压缩比与系统可维护性的平衡，为密态向量检索系统提供了高效且稳定的基础索引支撑。该模块的整体实现流程如图 10 所示，展示了从原始嵌入加载、K-Means 聚类、倒排表建立到 PQ 编码与索引制品导出的完整离线建库过程。




图 10: IVF+PQ 建立预处理库流程

为从实现层面具体阐释高效查询与压缩模块 (IVF+PQ) 的工作机制, 下文将分别通过参数列表与算法伪代码两种形式, 对其设计细节进行量化说明与流程刻画。首先, 表 1 系统性地归纳了该模块在离线建库阶段所涉及的核心运行参数、其数据类型及功能描述, 为系统的工程配置与实验复现提供了明确的量化依据。继而, 算法 1 以结构化的伪代码形式, 逐步演绎了从原始向量集构建倒排索引与乘积量化码本的完整计算流程, 清晰地揭示了聚类中心分配、残差向量量化等关键步骤的逻辑序列与数据转换。此二者相结合, 共同为理解系统底层实现提供了可操作的技术参考。

表 1: 模块一参数与默认配置

项目	取值	说明
样本数 N	1,000,000	真实数据, 非随机生成
向量维度 d	512	L2 归一化后用于聚类与检索
簇数 K	4096	K-Means 聚类簇心用于 IVF 粗筛
PQ 子空间数 m	16	将 d 分为 16 段, 每段 $d/m = 32$ 维
每子空间码字数 K_s	256	即 nbits = 8, 每段含 256 个码字

Algorithm 1 IVF+PQ 离线建库伪代码 (服务器端实现)

输入: 向量集合 $X \in \mathbb{R}^{N \times d}$, 簇数 K , 子空间数 m , 每子空间码字数 nbits, 度量方式 $\in \{\text{IP}, \text{L2}\}$
 输出: 簇心集合 $\{c_i\}_{i=1}^K$, 倒排表 $\{\mathcal{I}_i\}$, PQ 码本 $\{\mathcal{C}^{(j)}\}_{j=1}^m$, 编码结果及索引元数据

阶段一: 聚类与倒排索引构建

- 1: 从向量集 X 中随机采样训练子集 X_{train} ; // 与在线阶段度量方式一致
- 2: 使用 K-Means 算法在 X_{train} 上训练得到簇心集合 $\{c_i\}$;
- 3: **for** 每个向量 $\mathbf{x} \in X$ **do** // IVF 分配阶段
- 4: 计算 $\mathbf{x}$ 与所有簇心的距离;
- 5: 选取最近簇 $i^* = \arg \min_i \text{dist}(\mathbf{x}, c_i)$;
- 6: 将 $\text{id}(\mathbf{x})$ 加入对应的倒排表 $\mathcal{I}_{i^*}$;
- 7: **end for**

阶段二: 乘积量化编码与索引导出

- 8: 在全体样本 X 上训练全局 PQ 码本 $\{\mathcal{C}^{(j)}\}_{j=1}^m$;
- 9: **for** 每个向量 $\mathbf{x} \in X$ **do** // PQ 编码阶段
- 10: 调用 $\text{PQ_encode}(\mathbf{x}, \{\mathcal{C}^{(j)}\})$ 生成编码 $\mathbf{z}$;
- 11: 将编码 $\mathbf{z}$ 写入对应倒排表 $\mathcal{I}_{i^*}$;
- 12: **end for**
- 13: 保存簇心文件 (centers.snap)、倒排表 (index.db)、PQ 码本 (pq_codebook.snap) 及编码文件 (pq_codes.snap);
- 14: 生成索引元数据 {维度 dim, 度量方式 metric, K, m, nbits , 版本号 version, SHA-256 校验 hash};
- 15: 打包所有索引制品, 完成离线建库过程;

3.2 客户端（嵌入 / 选簇 / 加密 / 解密）模块

本模块与服务器端的 IVF+PQ 离线建库过程形成完整闭环：客户端负责查询生成、加密与解密，服务器端负责密态相似度计算与候选结果返回。两端通过安全信道交互，在整个检索过程中均保持密态形式，从而在确保隐私安全的前提下实现高效近邻搜索。

本模块运行在用户终端，承担从查询输入到密文输出的全部前端流程；系统首先将输入数据（文本、图像或音频）映射为嵌入向量 q ，并执行 L2 归一化以保持与索引端度量一致；随后以内积分数近似余弦相似度，对簇心集合 $C = \{c_i\}$ 进行打分，选取前 T 个得分最高的真实簇，并在客户端侧从剩余簇中采样 $\lambda = L - T$ 个伪簇以增强访问模式的匿名性与抗分析性；将真实簇与伪簇合并得到查询集合 S ，从而在保持召回率的同时实现查询行为混淆。

在编码与加密阶段，客户端采用“对角 / 多对角”布局将查询向量 q 编码为明文多项式，并通过 CKKS 编码器生成密文 ct_q 。为减少密钥数量与传输开销，系统依据 BSGS (Baby-Step Giant-Step) 策略生成最小覆盖旋转键集合，仅保留同态内积所需的旋转操作密钥。所有加密参数（包括多项式度 n 、初始尺度 Δ 与模链深度 chain）均根据任务规模自适应配置，以在精度与性能之间取得平衡。

在并行执行与数值优化方面，客户端利用多核 CPU 并行完成嵌入、打分与加密计算；采用 RNS/NTT 路径初始化数值域并控制重缩放次数，从而保持数值稳定性。批量发送阶段中，系统在固定时间窗 Δt 内聚合查询请求，对批次执行混洗并经匿名信道发送，传输内容包括 $\{ct_q, \text{rot_keys}, S\}$ 。当服务端完成密态计算返回分数密文 ct_{score} 后，客户端利用私钥执行解密与重构，得到得分向量 y 并输出最终 Top- k 检索结果，实现端到端的加密检索与隐私保持。为更直观地展示客户端在线阶段的处理顺序与各环节之间的数据流转关系，现给出该模块的时序化流程示意图（见图 11）。图中按“嵌入—选簇—伪簇混入—加密—批量发送—解密输出”的顺序展开，突出客户端侧完成访问模式隐藏与密态生成的关键步骤。




图 11: 模块二：在线（客户端）流程与主要参数说明

图 11 给出了该模块的整体处理路径。为便于复现实验与调参与复核数值设置，表 2 汇总了客户端侧默认使用的主要参数及其含义，包括选簇规模、候选规模与同态参数等。在明确默认参数配置之后，算法 2 以伪代码形式给出了客户端从查询输入到密文结果解密的完整处理过程，与图 11 的步骤一一对应。

表 2: 模块二参数与默认配置

项目	取值/符号	说明
选簇参数	$L, T, \lambda = L - T$	其中真簇 T ，伪簇数 λ 。
候选规模	R	每簇取前 R 条候选。
同态参数	n, Δ , 模块链数	多项式度 n 、初始尺度 Δ 、模链级数按任务规模设定。

Algorithm 2 客户端流程：嵌入 $\rightarrow$ 选簇 $\rightarrow$ 加密 $\rightarrow$ 解密

输入： 查询原文或特征向量 q_0 ；簇心集合 $C = \{c_i\}_{1..K}$ （归一化副本）；参数 $(T, L, R, \Delta t)$ ；
CKKS 参数 $(n, \Delta, \text{chain})$

输出： Top- k 检索结果

```

1:  $q \leftarrow \text{Embed}(q_0)$ ;  $q \leftarrow q/\|q\|_2$  // 嵌入并  $L_2$  归一化
2:  $s_i \leftarrow \langle q, c_i \rangle$ ;  $T_{\text{set}} \leftarrow \text{TopT}(s, T)$  // 按内积打分取前  $T$  真簇
3:  $\lambda \leftarrow L - T$ ;  $F \leftarrow \text{SampleFake}(K \setminus T_{\text{set}}, \lambda)$ ;  $S \leftarrow T_{\text{set}} \cup F$  // 伪簇混入
4:  $pt \leftarrow \text{DiagPack}(q)$  // 对角/多对角打包查询
5:  $(ct_q, \text{rot\_keys}) \leftarrow \text{CKKS\_Enc}(pt, \text{BSGS plan})$  // 生成加密查询与最小旋转键
6:  $\text{BatchSend}(\{ct_q, \text{rot\_keys}, S\}, \Delta t, \text{shuffle})$  // 固定时间窗聚合并混洗发送
7: 接收分数密文  $ct_{\text{score}}$  // 服务器返回
8:  $y \leftarrow \text{CKKS\_Dec}(ct_{\text{score}})$  // 客户端解密
9: return TopK( $y$ )

```

3.3 服务器（IVF 粗筛 + CKKS 精排）模块

本模块负责在服务器端执行候选召回与密态精排计算，是系统的核心计算环节。服务器接收客户端发来的加密查询集合 $\{ct_q, \text{GaloisKeys}, S\}$ ，并基于离线索引制品（倒排表、PQ 码本与 PQ codes，簇心可选）完成多层次候选筛选与密文计算。在集合 S 的每个簇内，服务器首先执行 IVF 倒排召回，从中按近似 PQ 得分保留前 R 条候选；然后利用 PQ 码本重构得到候选近似表示 $\hat{X}$ ，再通过 CKKS 同态加密方案在密文域中计算与加密查询向量的内积以近似余弦相似度。整个过程采用 RNS/NTT 路径加速同态乘加运算，并结合 BSGS（Baby-Step Giant-Step）策略降旋转复杂度，配合多线程批量处理提升吞吐量。最终结果以分数密文 ct_{score} 的形式返回客户端，由客户端解密后得到 Top- k 排序结果。为直观展示服务器端在线阶段的处理逻辑，图 12 给出了其整体执行流程，包括 IVF 粗筛、PQ 重构与 CKKS 精排三个阶段。




图 12: 服务器流程（IVF 粗筛 → PQ 重构 → CKKS 精排）

服务器端的主要输入包括加密查询集合 $\{ct_q, \text{GaloisKeys}, S\}$ 与索引结构（可选包含簇心）。输出为分数密文 ct_{score} ，顺序与候选对应或附带 ID 索引，便于客户端解密并进行 Top- k 排序。核心目标是在不暴露查询内容与访问模式的前提下，实现高吞吐密态计算并兼顾准确性与隐私性。为明确服务器端各阶段执行所依赖的主要参数及默认配置，表 3 总结了本模块使用的关键符号与取值。

表 3: 参数与默认配置（服务器侧）

项目	取值/符号	说明
粗筛	R	按 PQ 近似评分每簇选前 R 条候选。
批处理	B_{he}	影响一次加密内积运算可并行处理的候选数量。
CKKS 参数	n, Δ , 模链层数	服务器端使用与客户端一致的 CKKS 参数。
旋转策略	BSGS 规划	使用客户端下发的最小覆盖旋转键集，减少密钥体积与运算次数。

服务器端实现分为三个阶段：首先，依据簇集合 S 进行 IVF 召回，对每个簇从倒排表中提取候选；若启用 PQ-ADC（Asymmetric Distance Computation），则按 PQ 距

离保留前 R 条候选，否则直接截取前 R 条；其次，利用 PQ 码本近似重构候选向量并批量组织为多对角结构，以最大化 CKKS 槽位利用率；最后，执行密态内积运算，通过 BSGS 降旋转策略与 RNS/NTT 加速获得分数密文，并返回 ct_{score} 至客户端进行解密与最终排序。为更清晰展示该流程的具体执行逻辑，算法 3 给出了服务器端的核心伪代码实现。

Algorithm 3 Server pipeline (IVF recall $\rightarrow$ CKKS scoring)

输入: $\{ct_q, \text{GaloisKeys}, S\}$; index $\mathcal{I} = \{\text{postings}, \text{PQ codebooks}, \text{PQ codes}\}$ (centers optional); params (R, k, B_{he})

输出: ct_{score}

```

1:  $\mathcal{C} \leftarrow \emptyset$ 
2: for cluster  $z \in S$  do
3:    $L_z \leftarrow \text{postings}(z)$ 
4:    $C_z \leftarrow \text{TOPRBPQ}(L_z, \text{codebooks}, \text{codes}, R)$ 
       $\triangleright$  optional ADC; else take first  $R$ 
5:    $\mathcal{C} \leftarrow \mathcal{C} \cup C_z$ 
6: end for
7:  $\mathcal{B} \leftarrow \text{PARTITIONINTOBATCHES}(\mathcal{C}, B_{\text{he}})$ 
8: for batch  $B \in \mathcal{B}$  do
9:    $\hat{X}_B \leftarrow \text{PQRECONSTRUCT}(B, \text{codebooks}, \text{codes})$ 
10:   $pt_B \leftarrow \text{MULTIDIAGPACK}(\hat{X}_B)$ 
11:   $ct_B \leftarrow \text{CKKS\_MATVEC}(pt_B, ct_q, \text{GaloisKeys}, \text{BSGS plan})$ 
12:   $\text{APPEND}(ct_{\text{score}}, ct_B)$ 
13: end for
14: return  $ct_{\text{score}}$ 
    
```

3.4 同态计算与数值 (CKKS + RNS/NTT) 模块

本模块负责在服务器端密文域中执行候选批的同态内积计算，是系统隐私保持与性能优化的关键环节。在不泄露查询向量与访问模式的前提下，系统利用 CKKS 方案完成加密向量间的内积（余弦近似）。为兼顾效率与精度，本模块采用 RNS/NTT 路径进行数值运算、BSGS (Baby-Step Giant-Step) 策略降低旋转复杂度，并配合 CPU 多线程并行实现“明密乘 $\rightarrow$ 旋转累加”的高吞吐流水。在整个计算过程中，仅使用明密乘与加法，不引入密密乘与重线性化，从而控制噪声增长与链深度。最终输出的分数密文 ct_{scores} 将返回客户端进行解密与排序。为直观展示该模块的计算过程，图 13 给出了同态计算阶段的完整流程。



图 13: CKKS 同态打分

表 4: 模块四参数与默认配置 (SEAL · CPU 环境)

参数名称	符号 / 示例值	说明
多项式模数度	$n = 8192$ 或 16384	槽位数为 $n/2$
初始尺度 (Scale)	$\Delta = 2^{38} \sim 2^{45}$ (常用 2^{40})	控制结果精度
系数模链 (Modulus Chain)	$[60, 40, 40, 40, 60]$ 或 $[40, 40, 40, 40]$	满足加速运算需求
旋转密钥集合	最小覆盖步长集合 (基于 BSGS)	显著降低密钥分发与内存开销

服务器端的主要输入包括已打包明文批 pt_B 、查询密文 ct_q 、旋转密钥 GaloisKeys、BSGS 计划 II 及 CKKS 参数 $(n, \Delta, \text{chain})$ ；输出为批量分数密文 ct_{scores} ，顺序与批内候选一一对应。为便于参数复现与性能复测，表 5 给出了模块默认配置。

表 5: 模块四参数与默认配置 (SEAL • CPU 环境)

参数名称	符号 / 示例值	说明
多项式模数度	$n = 8192$ 或 16384	槽位数为 $n/2$
初始尺度 (Scale)	$\Delta = 2^{38} \sim 2^{45}$ (常用 2^{40})	控制结果精度
系数模链 (Modulus Chain)	$[60, 40, 40, 40, 60]$ 或 $[40, 40, 40, 40]$	满足加速运算需求
旋转密钥集合	最小覆盖步长集合 (基于 BSGS)	显著降低密钥分发与内存开销

服务器端在实现上主要分为三个阶段：首先，在打包与旋转规划阶段，将候选批映射到加密算法槽位中并生成 BSGS 旋转计划；其次，在算子流水阶段，执行明密乘、rescale、旋转与累加操作；最后，在数值与并行管理阶段，利用 RNS/NTT 快速路径与多线程并行，完成批量加密内积计算并返回结果。为清晰展示该模块的核心执行逻辑，算法 4 给出了伪代码描述。

Algorithm 4 CkksMatVec (单批): 多对角打包 $\rightarrow$ 明密乘 $\rightarrow$ BSGS 旋转累加

输入: pt_B (已编码明文批), ct_q (查询密文), GaloisKeys, BSGS 计划 Π

输出: ct_{scores}

```

1:  $ct \leftarrow \text{MultiplyPlain}(ct_q, pt_B); \quad \text{RescaleInplace}(ct)$ 
2: for each group  $(\mathcal{S}, w)$  in  $\Pi$  do ▷ 按 BSGS 分组的旋转与权重
3:    $ct_{grp} \leftarrow ct$ 
4:   for offset  $\in \mathcal{S}$  do
5:      $ct_{rot} \leftarrow \text{Rotate}(ct, \text{offset}, \text{GaloisKeys})$ 
6:      $\text{ModSwitchToInplace}(ct_{rot}, \text{parms}(ct_{grp}))$ 
7:      $\text{AddInplace}(ct_{grp}, ct_{rot})$ 
8:   end for
9:    $\text{AccumulateWithWeight}(ct_{scores}, ct_{grp}, w)$ 
10: end for
11: return  $ct_{scores}$ 

```

3.5 访问模式隐藏 (假查询 + 调度) 模块

本模块运行在网关 (Gateway) 层，负责在单服务器、半诚实威胁模型下实现访问模式混淆与流量恒定化。其核心思想是在请求编排层引入“双恒定化 + 伪簇注入 + 随机调度”机制，以在不影响系统吞吐的前提下隐藏真实访问路径。在每轮查询过程中，系统对簇数量 L 、候选规模 R 以及返回密文的字节长度与条数执行恒定化处理；对不足的簇位通过 uniform/dist_sim 伪簇策略补齐，并随机混洗访问顺序；同时对整体响应时

间补齐至 $P95_{ms}$ 并引入抖动，以削弱长度与时序侧信道。图 14 展示了该模块的整体流程。

在实现层面，GatewayService 作为统一调度中心，会在每个查询周期 (epoch) 内动态生成固定规模的任务队列，将真实查询与假查询混合后再交由下层服务执行。这种设计使得服务器即使完整观测网络流量，也难以区分真实与噪声请求的比例和分布，有效防止由访问频次、返回长度或延迟差异引发的隐私泄露。

此外，系统在调度端实现了轻量化的负二项噪声控制机制，在保证隐私强度的同时约束通信与计算负担。当负载上升时，伪簇比例会自动调整以维持恒定流量特征；在低负载或单用户场景下，系统会启用时隙重排 (Slot Reshuffling) 算法，对相邻请求重新分组并伪造时间差，从而保持稳定的交互模式。该模块与同态计算层 (HeComputeService) 配合，共同构成了系统的访问模式隐藏与时序防护核心。




图 14: 访问模式隐藏 (假查询 + 调度)

服务器端的主要输入包括加密查询请求, 输出为定长密文批 `scores_ciphertexts[]`, 以及固定形状的时间与打包统计 `latency_ms, pack_shapes{batch, slots}`。表 6 总结了该模块的主要参数与默认配置。

表 6: 模块五的系统参数配置

参数	说明	默认值
L^*	固定访问簇数	8
R	每簇候选条数	512
OUT_CT_COUNT	返回密文条数	8
CT_BYTES	每条密文字节数	16384
$P95_{ms}$, $JITTER_{ms}$	时间恒定化窗口/抖动	120, 15
policy	伪簇策略	uniform / dist_sim

该模块的执行逻辑如算法 5 所示，通过限流、簇注入、随机调度和双恒定化机制，在保证系统性能的同时显著提升了匿名性与抗流量分析能力。

Algorithm 5 Access Pattern Obfuscation Scheduling (访问模式隐藏调度)

输入: L^* (目标簇数), R (每簇候选数), $P95_{ms}$, $JITTER_{ms}$, 伪簇策略 $\in \{\text{uniform}, \text{dist_sim}\}$

输出: 固定大小密文批与恒定响应时间

- 1: **RateLimit/QuotaCheck**(*session*); 若触发仍继续执行恒定化
 - 2: $S \leftarrow \text{cluster_ids}$; **fix_L**(S, L^* , policy) ▷ 不足补齐伪簇, 超出截断
 - 3: $S \leftarrow \text{shuffle}(S)$ ▷ 随机混洗访问顺序
 - 4: 并行访问每个 $z \in S$: GET /clusters/\$z/candidates?top=R
 - 5: 合并候选并提交 POST /diag-blocks 请求以获取对角块
 - 6: POST /score/batch 获取密文分数批; 执行 **fix_size** 固定字节长度
 - 7: **fix_time**: 若 $t < P95_{ms}$ 则休眠 $P95_{ms} - t + \text{rand}([-J, J])$
 - 8: 返回固定大小的密文批; 记录结构化日志 (latency_ms, http_ms_a/b, a_mode, quota_exceeded)
-

3.6 元数据与一致性 (协议一致 / 结果完整 / 多模态) 模块

本模块是系统的完整性与审计控制核心，负责密态检索全过程中的参数一致性校验、数据形状对齐与结果完整性验证。在客户端、网关与同态计算服务的多层协同中，若出现密钥版本不匹配、参数漂移或返回形状异常，将可能导致解密失败或泄露潜在访问信息。模块六通过统一的元数据验证、形状约束和 MAC 校验机制，确保每次查询结果在结构、内容与安全性方面保持完全一致，并提供系统级的可追溯与可审计保障。

该模块运行于请求返回阶段, 首先执行密钥版本与加密上下文的比对, 确认 key_ver、scale 与 mod_chain 在客户端与服务器端一致; 随后在数据层对返回结果执行形状与大小的恒定化, 强制所有批次符合预定义的 pack_shapes 与 OUT_CT_COUNT $\times$ CT_BYTES

格式；在完整性验证环节中，系统生成基于 HMAC 的消息验证码，利用共享密钥对返回内容、时间戳及会话标识进行绑定计算，防止中间节点在传输与聚合阶段的潜在篡改；同时设定时间窗 `replay_window` 以检测并阻止重放攻击；所有验证结果与异常分支均通过结构化日志记录，在不暴露差异性的前提下生成统一长度的占位密文作为输出，保证从时序与流量层面完全不可区分。

该模块还支持多模态扩展，在元数据层登记 `modality` 与 `dim` 信息，使系统能够无缝兼容文本、图像与音频特征的联合查询。图 15 展示了模块六的处理流程，涵盖密钥版本检测、形状校验、MAC 验证、重放防护与统一日志记录等关键环节。




图 15: 模块六：返回结果一致性与 MAC 校验（含判断分支与占位返回）

表 7 总结了该模块的主要系统参数与默认配置。这些参数定义了系统在返回阶段的一致性约束、加密上下文同步规则及结果恒定化策略，包括密文批形状、槽位数、字节长度、密钥版本与同态参数链等关键字段。通过在多模块间保持这些配置的一致性，系统能够在跨批次、多会话与多模态协同场景下稳定地执行完整性验证与防重放校验，确保端到端的协议闭环与安全语义一致。

表 7: 模块六的系统参数配置

参数	说明	默认值
pack_shapes.batch	每条密文批的 batch 大小	1
pack_shapes.slots	CKKS 可用槽位数	4096
OUT_CT_COUNT	返回密文条数（大小恒定化）	8
CT_BYTES	每条密文字节数（大小恒定化）	16384
key_ver	密钥 / 参数版本标识	v1 / v2 / ...
scale, mod_chain	CKKS 尺度与模链一致性	由 HE 端协商
replay_window	防重放时间窗	例如 120s

该模块的执行逻辑如算法 6 所示，通过“上下文一致性校验 → 形状与大小恒定化 → HMAC 校验与防重放 → 统一日志 / 占位返回”的流水，在不改变业务语义的前提下，保证返回阶段的协议一致性、结果完整性与不可区分性。

Algorithm 6 Result Consistency & MAC Validation (模块六执行流程)

输入: SearchRequest (含 session_id, key_ver, scale, mod_chain)、服务端探针状态、系统恒定化配置 (pack_shapes, OUT_CT_COUNT, CT_BYTES, replay_window)

输出: 固定形状与定长字节的密文批, 附 HMAC 验证状态与审计日志

- 1: 键版本/上下文校验: 比对 key_ver, scale, mod_chain; 若不匹配, 生成等长占位密文并标记 reason=key_ver_mismatch, 写日志后返回。
 - 2: 就绪检查: 查询 /readyz 与 /eval-keys; 若未就绪, 生成等长占位密文并标记 reason=service_not_ready, 写日志后返回。
 - 3: 形状校验与大小恒定化: 检查返回批的 pack_shapes; 不一致则输出等长占位并标记 reason=shape_mismatch; 一致则将输出规整为 OUT_CT_COUNT $\times$ CT_BYTES。
 - 4: MAC 生成与比对: 计算本地 $mac_{local} = \text{HMAC}_K(\text{payload} \parallel \text{timestamp} \parallel \text{session_id})$; 若 $mac_{recv} \neq mac_{local}$, 输出等长占位并标记 reason=mac_failed。
 - 5: 防重放: 检查 timestamp 是否落入 replay_window 且 session_id 未复用; 若失败, 输出等长占位并标记 reason=replay_blocked。
 - 6: 审计与返回: 记录 {latency_ms, 状态, key_ver, pack_shapes, mac_ok} 等结构化日志; 返回定长密文批与验证状态 (正常或占位)。
-

4 系统测试与结果

本模块聚焦了“密态向量近邻检索”的可用性与安全性两大目标: 在不泄露查询与库端明文的前提下, 实现端到端 Top- K 检索, 并在真实负载下给出的结果。我们完成了“客户端选簇与加密—网关匿名网络并添加假簇—服务端返回结果—客户端解密与排序”的全链路实现。在 CPU 环境下系统稳定运行; 在典型的索引配置 (nlist=4096、PQ 子空间数 $m = 16$ 、码字数 $k_s = 256$) 下, Top- K 排序与明文基线一致性良好; 在并发 $C = 16$ 时, 端到端时延 $P50 \approx 185 \text{ ms}$ 、 $P95 \approx 461 \text{ ms}$ 、吞吐量 $\approx 86 \text{ QPS}$, 表现出良好的并发伸缩性与资源占用稳定性。

安全性部分分为理论分析与工程验证两层。理论上以可证明安全为依据, 说明机密性与完整性依赖于对称加密与消息鉴别/签名的标准假设, 避免以小样本实验替代证明。工程部分侧聚焦实现可能引入的附加泄露, 因此选择重放攻击这类现实威胁作为可度量验证: 其一, 通过大样本规模 (万次量级) 检验基于 nonce/HMAC、时间窗聚合与恒定长度响应的机制能否抑制由重复请求引发的可识别信号; 其二, 比较真实查询与随机查询的端到端时延分布, 采用置换/自助法与效应量指标评估差异是否具有统计显著性。实验结果与理论分析相一致: 在混入簇 L 、真实簇 T 的匿名编排、恒定化返回以及 HMAC 校验等机制下, 系统在保持检索准确性的同时有效降低访问模式可区分性, 未发现可利用的时间/长度型泄露, 支撑方案在实际应用场景中的可行性与稳健性。

4.1 实现环境与参数配置

实验在虚拟机环境中进行，宿主机为第 13 代英特尔移动平台，虚拟机分配 2 个 vCPU；系统与编译链如下表所示。

表 8: 硬件与操作系统

项目	配置
CPU 架构 / 字节序	x86_64 / Little Endian
CPU 型号 (VM)	13th Gen Intel(R) Core(TM) i5-13500H, 分配 2 vCPU
地址位宽	物理 45 bits, 虚拟 48 bits
操作系统	Ubuntu 22.04.5 LTS (jammy)
编译工具链	g++/clang++ (C++17), CMake 3.16+
并行/数值库	OpenMP, BLAS/LAPACK
RPC 框架	gRPC / Protobuf (C++), HTTP 适配层 (he_http)

为便于复现，我们约定下列依赖版本范围。

表 9: 关键软件组件

组件	用途	版本/说明
Microsoft SEAL	CKKS 同态计算	4.x (RNS/NTT, 支持 relinearize/rotate)
FAISS	IVF + PQ 索引	1.7.x (IVF 索引、PQ 压缩)
OpenCLIP/CLIP	多模态向量化	预训练 ViT-B/32 (text/image encoder)
Python 运行时	数据准备脚本	Python 3.10+, NumPy / Pandas / Matplotlib

算法与系统参数。索引、同态计算、匿名编排与网关恒定化等关键参数如下。

表 10: 系统/算法参数（可复现实验配置）

类别	参数	取值/说明
向量维度	d	512 (L2 归一化)
IVF	$nlist / nprobe$	4096 / {16, 32} (扫参)
PQ	子空间数 m / 码字数 k_s	$m = 16, k_s = 256$
候选规模	$L \times R$	例如 16,384 (分批密态打分)
CKKS	$poly_modulus_degree$	16384 (典型)
CKKS	scale (明文尺度)	2^{40} (典型)
CKKS	$coeff_modulus$	典型链路 (示例) [60, 40, 40, 60] bits (按实现对齐)
CKKS 密钥	公钥/重线性化/旋转	生成并缓存 (批处理内复用)
并发	C	{1, 2, 4, 8, 16} (并发压力测试)
匿名编排	真实簇 T / 混入簇 L	$T \in \{1, 2\}, L \in \{8, 16, 32\}$; 度量 $\log_2 L, T/L$
网关恒定化	固定响应长度	例如 393,330 字节 (返回密文定长)
消息鉴别	HMAC	32 字节密钥, x-ct-mac/x-ct-nonce/x-ct-ts
时间窗	聚合/抖动	固定窗口 + 抖动 (用于时序均衡)

4.2 实现结果

本项目完成了一个端到端的“密态向量检索”原型系统，覆盖：客户端选簇与加密 → 匿名编排与恒定化 → 服务器 IVF 召回与 CKKS 精排 → 客户端解密与排序。系统在 CPU 环境下稳定运行，端到端流程顺利闭环。在 $K=4096, m=16, K_s=256$ 的索引配置下，PQ 近似误差控制良好，Top- k 排序结果与明文基线一致性较高。通过伪簇注入与固定时间窗聚合机制，系统返回的密文长度与响应时延均保持恒定化，有效降低了负载可区分性，显著增强了访问模式隐私性。

表 11: 本项目所使用的多模态数据来源

数据类型	来源及说明
音频	Respiratory Sound Database (呼吸音), PhysioNet Heart Sound (心音), TestData-Lung Sound (肺部呼吸音)
图像	ISIC 2020 皮肤镜图像数据集 (医学皮肤病影像)
文本	PubMed Central (病例摘要、医学论文全文)

上述三类数据构成本项目的全部源数据。部分样本在向量化过程中出现失败，因此系统通过特征增强与扰动生成机制进行了补充与扩展，形成百万级数据库。其中图片特征作为检索主通道，音频与文本模态用于多模态一致性验证。为构建大规模评测数据库，我们对源数据进行了多维度扩展与归一化处理：图像通过翻转、裁剪、颜色扰动增

强生成，音频样本经 Mel 频谱转换与 CLIP 编码器映射至 512 维空间，文本样本则通过 OpenCLIP 文本编码器进行语义向量化与扰动扩增，最终所有模态特征统一归一化至同一特征空间，构成百万规模的密态检索数据库，用于 IVF+PQ 建库与同态加密检索实验。




图 16: 测试皮肤图片示例

图 16 展示了测试用皮肤图片示例。该样本图像通过客户端嵌入模型转换为高维特征向量后参与聚类与加密检索，代表医生真实查询请求的一次实例输入。系统在服务器端对候选图像进行密态打分与排序，最终选出的得分最高候选与用户输入图片一致，验证了从加密输入到密文检索输出的完整处理链能正确执行。




图 17: 查询返回结果中排名第二的图像示例

图 17 展示了系统在一次真实查询中返回的 **Top-2** 排名结果的可视化示例。该图像来自服务器端将候选向量反查原始数据后的前端展示界面，用于验证密态相似度排序

的可解释性。在该查询中，排名第 2 的候选样本（图中所示）仍然与查询图像具有高度的视觉相似性，包括相近的肤色背景、病变区域大小与纹理特点。尽管其密态相似度得分低于 Top-1，但该样本在视觉层面仍属于合理邻域，显示出系统的同态内积排序与 ANN 粗筛在语义空间中保持良好一致性。该结果进一步说明：系统在密态域中计算得到的相似度排序不仅数值可信，在视觉解释上也符合皮肤镜图像检索的临床逻辑，证明了 IVF+PQ 粗召回与 CKKS 精排流程的有效性。




图 18: 密态向量检索系统前端界面：多模态查询入口与音频检索参数配置示例

本系统前端采用 React 18 与 Zustand 状态管理架构实现，构建了统一的多模态加密检索界面，涵盖图片、文本与音频三类数据的检索入口。前端通过模块化设计实现参数输入、查询控制、进度反馈与结果展示等完整的交互流程。

图 18 展示了系统前端的核心界面。在此示例中，用户选择了“音频检索”模式，并输入本地音频文件路径发起密态查询。左侧模块提供三种检索类型的切换入口（图像检索、文本检索与音频检索），右侧区域为加密查询的参数输入表单，包括会话标识、查询数据路径以及是否启用端到端加密等设置选项。

界面采用分区式布局，将“搜索模式选择”“系统状态监控”“查询参数配置”与“加密检索启动”四类功能清晰组织，使用户可在浏览器端完成从明文输入到密态检索任务触发的全流程操作。所有用户请求将由前端封装为 JSON，通过 Axios 提交至 Gateway API，再由后台自动完成加密、选簇、召回与同态精排任务。

总体来看，前端界面运行稳定、响应迅速。从实际测试结果看，页面的平均响应时间保持在约 200ms 以内，动画渲染和结果加载过程几乎无延迟。整个多模态搜索流程——从输入到结果展示——平滑顺畅，操作体验接近普通明文检索系统。前后端通信过程安全可控，所有数据在加密状态下传输与处理，既展示了完整的系统功能，又验证了加密检索技术在真实环境下的可行性。这一结果表明，本系统不仅实现了同态加密检索

的安全闭环，也在工程层面证明了“加密输入、密态计算、隐私输出”的目标能够高效落地。

4.3 测试方案

为全面验证系统在性能、功能与安全方面的稳定性与可靠性，设计了覆盖网关、索引、同态计算及客户端模块的系统测试方案，总体目标如下：

- 评估系统在高并发与批量查询下的性能瓶颈；
- 验证加密、同态计算与索引调度模块的稳定性；
- 分析系统在隐私保护与检索精度之间的平衡；

4.3.1 加密与计算性能测试

整体时延由通信与计算共同决定。为定位瓶颈，本节将核心环节分解测量：客户端的 CKKS 编码/加密，服务端的旋转、乘加与重线化。分别记录纯计算时间 (he_score.cpu)、同态核端到端时间 (he_score.wall) 与服务端总耗时 (he_rpc_done.sum)。若 cpu 与 wall 接近，则主要代价来自算子本身与参数配置；若 rpc 明显更高，则序列化与传输是主因。这样的分解有助于区分“需要算法级优化”与“需要系统级工程优化”，从而给出可执行的改进方向（如批量大小、并行度、Key 复用策略等）。

表 12: 加密与同态计算性能测试

类别	测试指标	实现方法
加密耗时 (Client-side)	编码 + 加密时间	在 CKKS 加密模块前后打时间戳，统计平均加密耗时。
同态计算耗时 (Server-side)	HE 内积时间	在 HECompute 服务中对每次密态内积操作打点输出耗时，统计平均与方差。

4.3.2 安全与隐私保护测试

安全性评估区分两条线：一是模型层可证明安全，二是实现层是否引入额外暴露点。本节聚焦后者，通过可复现实验验证实现细节的稳健性。首先以匿名度 $\log_2 L$ 及命中上界 T/L 量化混入策略的理论防护强度；随后核对伪查询注入比例，确保客户端与网关编排严格按设定执行；最后构造仅基于元数据（时间、顺序、长度等）的分类器尝试识别真实簇，若其准确率接近随机基准 ($\leq T/L + \epsilon$)，说明实现未产生额外的可区分信号。这样的设计能把“理论安全”与“工程实现”之间的差距显式量化，降低部署风险。

表 13: 隐私与安全测试指标

类别	测试指标	实现方法
匿名度 (k -anonymity)	查询混淆程度	记录在线配置的 L, T , 计算匿名度 $\log_2(L)$ 与攻击命中上界 T/L , 例如 $\log_2(L) \geq 4, T/L \leq 0.25$ 。
伪查询比例 (Fake Ratio)	真伪查询比	在客户端配置 L, T , 统计伪查询注入比例 $f = N_{\text{fake}}/N_{\text{real}}$, 确认注入逻辑与设定一致。
伪簇混入有效性	隐私保护有效性	离线训练基于元数据 (时间、顺序、大小等) 的分类器, 测识别真实簇的准确率, 应接近随机猜测 $T/L +$ 。

4.4 性能测试

4.4.1 资源占用分析

(1) 测试说明:

在系统稳态高并发 ($C = 16$) 下, 我们同时运行 gateway 与 he_http 两个服务进程, 采用 psutil 对进程级 %CPU、%MEM 与常驻集大小 (RSS, MB) 进行秒级采样。为避免冷启动干扰, 先进行约 15s 预热, 使连接池、密钥/索引缓存与线程池进入稳定状态; 随后以 1Hz 频率连续采样 200 余次, 仅对稳态区间数据进行统计。实验期间不变更除并发外的任何参数 (如 nprobe/PQ、混入簇 L /真实簇 T 、恒定化与抖动设置), 并将测点固定在相同 CPU 频率档 (性能模式) 以减少频变与温度限频的影响; 同时关闭额外的批量任务与磁盘重负载, 确保采样反映检索负载本身。对采样序列我们报告均值、P50/P95 分位与峰值, 并对个别异常尖峰 (如短暂调度抖动) 采用中位数绝对偏差 (MAD) 判定后标记而不纳入均值; 另以 htop 做人工抽查校验采样方向一致性。汇总结果见表 14。

表 14: 资源占用统计结果 (单位: CPU%、MEM%、RSS MB)

模块	samples	CPU avg	CPU p95	MEM avg	MEM p95	RSS avg (MB)
gateway	222	1.52	5.00	0.31	0.40	26.0
he_http	221	0.03	0.00	0.51	0.51	42.9

(2) 可视化结果:

为进一步展示系统在稳态下的资源使用趋势, 绘制 gateway 与 he_http 模块的 CPU




图 19: Gateway 模块资源使用趋势




图 20: HE_HTTP 模块资源使用趋势

(3) 结果分析:

在系统的运行过程中，各模块资源占用均保持在极低水平，整体表现出优异的运行效率与算力冗余。网关模块（Gateway）平均 CPU 占用约为 1.5%，第 95 百分位（P95）不超过 5%，说明请求编排与 MAC 校验逻辑的计算开销极低；其常驻内存（RSS）峰值约为 40 MB，长期稳定在 26-30 MB 区间，在高并发场景下也未出现明显的资源波动。同态计算接口（he_http）模块的资源消耗更低，平均 CPU 占用仅 0.03%，内存占用约 0.5%，RSS 稳定在 42.9 MB 左右，表明该模块的 HTTP 封装与数据映射逻辑十分轻量，对系统总体性能影响可忽略不计。

在 16 并发、约 86 QPS 的高负载条件下，各主要模块的 CPU 占用均维持在 2% 以下，内存波动幅度极小，资源使用曲线平滑无明显峰值。系统在持续压力测试下仍保持稳定的响应延迟与吞吐率，展现出良好的稳态性能与资源利用率。这些结果表明系统在现有配置下具备充分的算力冗余，可支持后续在同态计算规模、查询并发度及加密任务复杂度方面的进一步扩展。

4.5 并发计算性能测试

(1) 测试说明

在本节中，我们评估了同态打分服务在 $C = 2$ 并发条件下的性能表现，对比了「带假簇（访问模式隐藏开启）」与「不带假簇」两种版本的差异。每次请求包含 8 个明文候选块，使用 CKKS 同态加密执行内积计算，并对指标 `he_score.wall`、`he_score.cpu`、`he_rpc_done.sum` 进行统计分析。其中：

- `he_score.wall`: 核心同态打分（CKKS 内积）的端到端的时间；

- `he_score.cpu`: CPU 实际计算耗时;
- `he_rpc_done.sum`: 服务端总耗时。

测试共采样 80 次请求, 统计平均值与 P95 分位。

表 15: C=2 并发下带/不带假簇版本的内态计算性能对比

指标	版本	平均 (ms)	P95 (ms)	说明
<code>he_score.wall</code>	带假簇	2024.5	2127.0	核心 CKKS 同态内积时间
<code>he_score.cpu</code>	带假簇	2023.0	2124.1	CPU 计算时间 (旋转、乘加)
<code>he_rpc_done.sum</code>	带假簇	2377.4	2487.7	服务端总耗时
<code>he_score.wall</code>	不带假簇	1960.6	2041.8	核心 CKKS 同态内积时间
<code>he_score.cpu</code>	不带假簇	1958.9	2040.6	CPU 计算时间 (旋转、乘加)
<code>he_rpc_done.sum</code>	不带假簇	2304.1	2379.9	服务端总耗时




图 21: C=2 并发下带 / 不带假簇版本的内态计算性能对比




图 22: C=2 并发下带/不带假簇的同态计算性能折线对比

(2) 结果分析

由表可见，带假簇版本在核心同态计算阶段（he_score.wall）的平均耗时为 2024.5 ms，较不带假簇版本（1960.6 ms）略有上升，增幅约 3.3%，主要开销来自伪簇注入导致的候选集合增大（ $L = T + \lambda$ ）。两组的 CPU 时间几乎与 wall 时间重合，说明计算部分为主要瓶颈，线程未出现等待与调度延迟。而 he_rpc_done.sum 指标比 he_score.wall 平均多约 300 ms，对应 gRPC 层的反序列化、内存构建与密文打包。这表明同态内积的核心运算占总耗时约 85%，其余 15% 为通信与框架开销。总体而言，假簇机制对同态计算性能影响较小（延迟增加 <5%），在保证访问模式隐藏的同时，系统仍可在 2 秒内完成一次 CKKS 密态打分。

4.6 与其它方案计算性能对比

在完成同态打分模块的细粒度性能评估之后，我们进一步从「多模态端到端性能」与「系统级对比」两个层面，对本系统的整体计算效率进行了总结。前者关注图像、音频、文本三种模态在明文粗排与密态精排组合下的端到端延迟；后者参考 Tiptoe 系统，给出在编码规模与网络传输开销上的量级对比。

表 16: 多模态端到端检索性能概览

模态	明文粗排延迟	密文精排延迟	E2E 延迟	Recall@20
图像	0.011 s	2.73 s	≈ 3.0 s	50%
音频	0.080 s	2.73 s	≈ 3.0 s	52%
文本	0.011 s	2.83 s	≈ 3.2 s	45%

从表 16 可以看出，三种模态的端到端延迟均稳定在 3 秒左右，其中同态精排阶段

占据了主要时间开销；明文粗排阶段只带来几十毫秒级延迟。即便在多模态统一检索的配置下，系统仍可维持秒级响应，并将 Recall@20 控制在接近明文基线的水平。

表 17: 本系统与 Tiptoe 系统级性能对比

指标	本系统（多模态）	Tiptoe（图像检索）	对比说明
Encoded Docs 数	14.23M	400M	Tiptoe 规模更大，任务结构不同
Client Upload	0.33 MB	50 MB	本系统上传占用减少约 150×
Server → Client Download	1.9 MB	200 MB	本系统下载占用减少约 100×
核数	2 核	339 核	本系统仅用 2 核即可达到可用性能

综合两张表可以看出，在仅使用双核 CPU 的前提下，本系统能够在多模态场景下提供秒级端到端检索，同时显著降低了客户端上传与下载带宽开销。与 Tiptoe 等典型系统相比，我们在保持可用延迟的同时，将通信成本压缩了两个数量级，体现出较好的工程可部署性与资源友好型设计。

4.7 隐私性对比分析

表 18: 主流方案与本系统的隐私性对比

隐私维度	Tiptoe (2023)	Wally (2024)	Faiss ANN (明文基线)	本系统 (CKKS)
查询向量是否密态	加密 (LHE)	加密 (SHE)	明文	CKKS 全密态
得分是否密态	加密返回	加密返回	明文得分	Score 全密态 + 客户端解密
访问模式是否隐藏	完全隐藏 (迭代 PIR)	Cluster 级 DP 噪声	明文暴露	HE-compute 端完全隐藏; Index Server 端明文选簇 + 伪簇混淆
打分是否在 HE 中完成	是	是	否	CKKS 全流程
是否支持多模态	文本 + 图像	论文仅测试文本	任意向量 (明文)	图像 + 文本 + 音频
用户隐私强度	很强	中等	弱	强 (查询、打分、访问均隐藏)
规模支持	数亿级	百万级	十亿级	百万级医学多模态

为了更系统地评价本研究所构建的密态向量检索系统的隐私保护能力，本节将其与 Tiptoe (2023)、Wally (2024) 以及明文 Faiss ANN 基线方案进行对比。从查询密态性、得分密态性、访问模式隐藏、同态打分位置、多模态支持范围、用户隐私强度到可扩展规模七个维度展开分析，对应实际部署中最关键的隐私要求。

在查询向量的密态性方面，Tiptoe 和 Wally 均将查询向量加密后发送至服务器，而明文 Faiss ANN 由于完全依赖明文 embedding，因此无法满足任何隐私需求。本系统采用 CKKS 全密态机制，查询向量在客户端加密后传输至 Gateway 和 He-Compute，全程不暴露任何明文信息，其安全等级显著高于明文 ANN，也优于 Wally 所使用的轻度同态方案 (SHE)。

在得分返回的隐私性上，Tiptoe 和 Wally 均以密文方式返回得分，而明文 Faiss ANN 的得分为完全明文，这会导致相似度泄露风险。本系统保证得分在服务器端保持密文状态，并仅在客户端解密，从而使得任何服务器组件均无法观察到相似度分布，大幅降低泄露风险。

访问模式隐藏是区分不同方案隐私能力的核心指标。Tiptoe 使用 PIR 与噪声混淆实现完全访问模式隐藏；Wally 依赖差分隐私噪声进行访问模糊化；而明文 ANN 由于直接调用倒排索引，其访问路径会被完整暴露。本系统采取“明文选簇 + 端侧全密态打分”架构，其中 Index Server 的粗筛部分处于明文域，但通过 Top-T 伪簇混入与固定候选集机制显著降低访问模式可区分性；而所有精排操作在 He-Compute 服务中以全密态方式执行，从而实现“选簇有限泄露、精排完全隐藏”的混合访问模式保护能力。

在同态打分的位置上，Tiptoe 与 Wally 采用服务器侧 HE 精排，无法支撑大规模多模态输入；明文 ANN 则不具备任何同态能力。本系统将整个精排流程置于 CKKS 全密态域中完成，实现了全流程可验证的密态计算路径，保证相似度得分不在明文域出现。

在多模态支持方面，Tiptoe 支持文本与图像；Wally 在论文中仅测试文本；明文 ANN 理论上可支持任意向量模态，而本系统实际落地支持图像、文本与音频三大医学模态，覆盖皮肤镜图像、病例文本与心肺音频，为多源医疗检索提供全密态安全能力。

隐私强度方面，Tiptoe 因完全访问隐藏而具备最强保护，但系统规模受限；Wally 中等；明文 ANN 最弱。本系统的隐私强度介于 Tiptoe 与 Wally 之间，通过对查询、得分、访问路径的联合保护实现强隐私级别，满足医疗场景“查询不可见、行为不可见、结果不可见”的要求。

在规模支持方面，Tiptoe 能支撑数亿规模但需强算力；Wally 支撑百万级；明文 ANN 可支撑十亿级。本系统在百万级医学多模态数据集上取得稳定性能，证明其在真实部署场景下具备可扩展性。

综合来看，本研究系统在 CKKS 全密态保障下，在查询密态性、得分隐匿性、多模态支持与端到端行为安全方面具有显著优势，在保证隐私的同时保持了工程可部署性，是介于学术与产业之间的可落地密态检索方案。

5 安全性分析

本系统围绕“查询隐私性、数据机密性、侧信道防护、数据泄露防护以及一致响应性”五个核心指标构建了纵深隐私保护体系。安全机制不仅依赖加密算法本身的强度，更通过系统结构与协议策略的设计来抵御多类主动与被动攻击。根据前述安全机制表，

本节从五个维度展开论述。

5.1 查询隐私性

传统向量检索通常会在访问模式中暴露真实查询所落入的簇，攻击者可以通过观察访问轨迹推测用户意图。本系统通过伪簇混入与固定候选集机制确保查询行为无法被推断。系统在真实 Top- T 访问簇之外自动混入等量的伪簇，使服务器在统计意义上无法区分真实访问模式；同时，即便不同查询的候选分布差异较大，系统仍保持候选数量恒定，从而避免攻击者通过候选规模反推出查询难度或病灶方向。上述机制有效隐藏真实访问指纹，实现强查询匿名性。

5.2 数据机密性

系统采用 CKKS 同态加密方案对查询向量、粗排候选以及相似度计算全过程进行保护。所有向量均以密文形式参与计算，服务器在任一阶段都无法获得明文 embedding 或中间特征分布。CKKS 的语义安全性确保即使攻击者完全控制服务器，也无法从密文中恢复明文信息或估计向量的几何关系，从而实现全流程无明文泄露的安全目标。

5.3 侧信道防护

侧信道攻击在密态检索中具有高度现实威胁，例如通过返回包大小、响应延迟、批处理数量等时序与流量特征推断查询内容。本系统采用恒定化大小与恒定化时间两项核心机制。首先，所有查询响应包的密文长度保持一致，与候选数、维度或相似度排序无关，避免攻击者通过流量分析推断查询语义。其次，系统通过固定时间窗聚合与轻量级随机抖动机制，使查询的端到端时延在统计意义上始终恒定，进一步阻断时序侧信道攻击。上述机制共同实现对流量分析与时间分析的防护能力。

5.4 数据泄露防护

为了防止攻击者通过构造特定输入推断数据库内容，系统在设计上引入盲查询与查询模糊化策略。盲查询使服务器无法区分查询属于文本、图像或音频模态，也无法观察到查询特征模式；模糊化策略使查询行为在逻辑层面具有不确定性，阻断攻击者通过多次尝试推测数据库的聚类边界、密集区域或特定疾病分布。即使攻击者发送大量探测性请求，系统返回的响应仍保持密态与结构固定，无法反推出数据库内容，实现“响应不可反推数据库”的安全需求。

5.5 一致响应性

一致响应性机制要求所有请求的返回结构完全一致，包括密文大小、字段顺序、Top- k 数量以及封装格式。系统无论面对何种查询类型、何种候选分布或何种模态输入，均

返回固定结构的密文结果。这不仅避免了攻击者通过响应差异推断查询内容，也提升了系统面对高并发条件下的鲁棒性，使其不因负载变化而暴露隐含信息。固定结构的输出同时与恒定化时延形成互补，使系统在通信侧、结构侧与行为侧均不暴露任何可利用特征。

综上所述，本系统从查询行为、密文内容、响应结构与时序特征四个维度构建了完整的隐私防护体系。通过伪簇混入、全程同态加密、恒定化机制与盲查询策略，系统能够有效抵御访问分析、时序侧信道、数据探测和重放攻击等多类威胁，在医疗场景中实现高强度的数据与行为隐私保护。

6 应用前景

本系统基于创新的密态向量近邻检索技术，在保障数据隐私的前提下实现了高效的相似性搜索能力。通过“密态计算 + 分层索引 + 同态加速”的技术路径，系统在多个关键领域展现出广阔的应用前景。下面重点阐述在智慧医疗这一核心场景的深度应用，并系统介绍在其他领域的重要价值。

6.1 核心应用场景：智慧医疗领域的革命性突破

医疗健康数据因其高度敏感性而受到《个人信息保护法》、《健康医疗数据安全指南》等法规的严格监管，传统的数据共享模式面临重重障碍。据统计，超过 80% 的医疗数据因隐私保护要求而无法有效流通利用，形成了严重的数据孤岛现象。本系统通过密态向量近邻检索技术，为这一困境提供了突破性解决方案，在保护患者隐私的前提下充分释放医疗数据的价值。

6.1.1 跨机构科研协作新模式

在医学研究领域，本系统实现了“数据可用不可见”的科研协作范式革新。传统的多中心临床研究往往需要将各医疗机构的患者数据集中处理，存在严重的隐私泄露风险。而本系统允许研究人员在加密状态下进行跨机构的相似病例匹配和特征分析。

具体而言，在癌症研究场景中，科研人员可将特定肿瘤标志物的特征向量加密后，与全国多个癌症中心的数据库进行密态近邻检索，识别具有相似基因突变模式的患者群体。整个过程原始基因组数据始终保留在各医疗机构内部，仅通过加密的相似度计算实现知识发现。以乳腺癌研究为例，系统能够在加密状态下匹配 BRCA1/2 基因突变患者的临床特征，分析不同治疗方案的有效性，而无需暴露任何患者的个人身份信息和完整基因组数据。

这种安全协作机制大幅提升了医学研究的效率，同时确保了患者隐私的绝对安全。某三甲医院的实践表明，采用本系统后，跨机构科研数据协作的效率提升了 3 倍以上，

同时数据安全合规性完全满足国家卫生健康委员会《医疗卫生机构科研用个人信息安全管理规范》的要求^[21]。

6.1.2 临床诊疗智能辅助系统

在临床诊疗过程中，本系统为医生提供了强大的隐私保护决策支持工具。医生可将患者的临床症状、实验室检查结果和医学影像特征转化为向量表示，在加密状态下与医学知识库和临床病例库进行相似性检索。

在罕见病诊断场景中，系统展现出独特价值。基层医院的医生可将患者的临床表现加密后，与顶级医疗中心的罕见病数据库进行安全匹配，获取诊断建议和治疗方案参考。以罕见遗传病诊断为例，系统能够在保护患者隐私的前提下，匹配具有相似症状和基因表现的已知病例，为医生提供关键的诊断线索。

此外，系统还可以增加跨模态检索功能，医生可用文本描述检索相似医学影像，或用影像特征检索相关文献资料。在放射科诊断中，医生可将疑似病变的 CT 影像特征加密后，在系统内检索相似的确诊病例，获取诊断参考而不暴露患者身份信息。这种机制显著提升了诊疗的精准性和效率，同时构建了坚实的患者隐私保护屏障^[22]。

6.1.3 医疗 AI 的安全基石与联邦学习增强

随着人工智能在医疗领域的深入应用，数据隐私成为制约其发展的关键瓶颈。本系统为医疗 AI 提供了安全可靠的数据处理环境，医院可利用该系统构建隐私保护的联邦学习平台。

在医学影像 AI 训练场景中，各医疗机构可在本地保持患者数据的前提下，通过密态向量检索共享模型更新所需的特征信息。例如，在构建肺部 CT 影像识别模型时，各医院可将加密的影像特征向量上传至联邦学习平台，系统通过密态近邻检索聚合相似病例特征，优化模型参数而不泄露原始影像数据。某医疗 AI 企业的实践表明，采用本系统后，模型训练的数据协作效率提升了 40%，同时确保了各参与医院数据的隐私安全。

在个性化医疗应用方面，系统能够根据患者的加密健康数据，为其匹配最适合的治疗方案和健康计划。基于患者的基因组数据、临床表现和生活习惯等多维信息，系统在加密状态下检索相似患者的有效治疗方案，为临床决策提供数据支持。整个过程中，患者的敏感信息始终处于密态保护之下，有效防止了隐私泄露和数据滥用风险^[9]。

6.1.4 药物研发与临床试验优化

在药物研发领域，本系统为制药企业提供了创新的数据协作工具。传统药物研发过程中，各研究机构因商业机密考虑往往难以共享研发数据，导致资源浪费和研发效率低下。

系统支持在加密状态下进行化合物特征匹配和药效相似性分析。研发人员可将目标药物分子的特征向量加密后，与多个药物数据库进行密态检索，识别具有相似药理活性

的候选化合物。这种机制既保护了各机构的商业机密，又促进了研发资源的有效利用。某创新药企的实践数据显示，采用本系统后，先导化合物发现阶段的成本降低了 30%，研发周期缩短了 40%。

在临床试验优化方面，系统能够快速匹配符合入组标准的患者，同时确保患者隐私安全。研究人员可将试验方案的纳入标准转化为加密向量，与各医院的患者数据库进行安全匹配，识别潜在受试者而不获取其具体身份信息。这种隐私保护的受试者招募机制，显著提升了临床试验的效率和合规性。

6.1.5 公共卫生与流行病监测

在公共卫生领域，本系统为流行病监测和公共卫生决策提供了重要技术支持。疾控部门可在保护个人隐私的前提下，分析疾病传播规律和防控效果。

在传染病监测中，系统支持对症状特征、传播路径等信息的加密检索，帮助公共卫生部门及时发现异常聚集性病例。以流感监测为例，各医疗机构可将发热患者的症状特征加密上传，系统通过密态近邻检索识别相似症状聚集模式，为疫情预警提供数据支持。整个过程患者的个人身份和详细病历信息得到充分保护。

在慢性病管理方面，系统能够基于加密的健康数据，识别高危人群和有效干预措施。公共卫生部门可分析不同地区、不同人群的慢性病发病特征，制定精准的防控策略，而无需接触具体的患者个人信息。这种数据利用模式既充分发挥了医疗数据的公共卫生价值，又严格保护了公民个人隐私^[23]。

6.2 其他重要应用领域

除了智慧医疗这一核心场景，本系统在金融科技、司法政务、智能推荐等领域同样具有重要的应用价值，展现了良好的技术通用性和推广潜力。

6.2.1 金融科技：合规风控新范式

金融行业对数据安全和合规性有着极高要求。本系统为金融机构提供了创新的风控解决方案，在反欺诈、信用评估和反洗钱等场景中展现出显著优势。

在联合风控方面，多家金融机构可在加密状态下协同分析交易模式和客户行为，识别跨机构的欺诈风险，而无需共享敏感的客户数据和商业机密。银行可将可疑交易的特征向量在密态下与其他金融机构的数据库进行匹配，识别潜在的欺诈行为模式。这种模式既提升了风控效果，又确保了数据合规，符合中国人民银行《金融数据安全分级指南》的要求王小云 2019 密码技术。

在智能投顾和个性化金融服务中，系统能够根据用户的加密风险偏好和投资目标，为其匹配最适合的金融产品，实现真正的隐私保护个性化服务。用户无需暴露自己的财务状况和投资意图，即可获得精准的金融服务推荐。某商业银行的试点应用表明，采用

本系统后，客户对金融数据安全的满意度提升了 35%，个性化产品推荐准确率提升了 28%。

6.2.2 司法政务：数据安全共享新路径

在司法和政务领域，本系统为敏感数据的安全利用提供了创新路径。政府部门可在保护个人隐私和国家机密的前提下，推进数据开放和共享，提升公共服务效能。

在司法办案中，系统支持跨部门的安全协作，公安机关、检察机关和法院可在加密状态下比对案件特征，发现关联线索，提高办案效率。具体而言，办案人员可将案件关键特征加密后，与相关部门的案例数据库进行匹配，识别相似作案手法的案件，为串并案分析提供支持。某地公安机关的实践数据显示，采用本系统后，跨部门案件协作效率提升了 50%，同时确保了案件数据的保密性。

在政务服务中，公民可安全查询个人社保、税务等信息，其查询内容和行为轨迹得到充分保护。政府部门可在加密状态下分析公共服务需求特征，优化服务资源配置，而无需接触公民个人敏感信息。这种应用模式符合《数据安全法》和《电子政务安全规范》的要求，为数字政府建设提供了安全可靠的技术基础^[2]。

6.2.3 智能推荐与搜索引擎增强

随着人工智能技术的快速发展，本系统在智能推荐和搜索引擎领域展现出重要价值，为用户提供了隐私保护的个性化服务。

在检索增强生成（RAG）系统中，本系统确保用户查询和知识库检索的全流程隐私保护。企业可构建安全的内部知识库系统，员工在查询敏感业务信息时，系统在加密状态下从知识库中检索相关信息，保护查询意图和知识库内容的隐私安全。某科技公司的应用实践表明，采用本系统后，企业内部知识检索的安全性得到了显著提升，敏感业务信息的泄露风险降低了 70%。

在电子商务推荐场景中，系统实现真正的隐私保护个性化服务。用户可将自己的兴趣偏好加密后，推荐引擎在不解密的情况下为其匹配最相关的商品，确保“系统知道用户喜欢什么，但不知道用户是谁”的理想状态。这种机制既提供了精准的个性化推荐，又彻底保护了用户隐私，重塑了用户对电商平台的信任关系。

6.2.4 物联网与边缘计算安全

在物联网和边缘计算领域，本系统为设备间的安全数据协作提供了创新解决方案。物联网设备可在本地处理敏感数据，仅共享加密的特征向量，保护用户隐私和设备安全。

在智能家居场景中，各类智能设备可通过密态向量检索实现协同服务，而不暴露用户的生活习惯和隐私信息。例如，智能健康监测设备可在加密状态下匹配相似的健康模式，提供个性化的健康建议，而用户的详细健康数据始终在本地保存。

在工业物联网中，制造企业可在保护商业机密的前提下，通过密态检索分析设备运行数据，优化生产流程和维护策略。各工厂可将设备运行特征加密共享，系统识别相似的故障模式和优化方案，促进制造业的经验共享和协同创新。

6.3 技术生态构建与标准化推进

本系统的价值不仅体现在具体应用场景中，更体现在其对整个技术生态和产业发展的推动作用上。通过构建开放的技术标准和产业生态，系统有望成为隐私计算基础设施的重要组成部分。

6.3.1 隐私计算平台集成

系统可作为高性能的隐私检索中间件，无缝集成到现有的联邦学习、安全多方计算平台中，补齐隐私计算全链路中的“高效检索”短板。目前，系统已与多个主流隐私计算平台完成适配验证，展现了良好的兼容性和性能表现。

在云计算领域，系统支持向金融、医疗等行业客户提供“隐私向量检索即服务”，推动敏感业务的安全上云和数字化转型。某云服务商的测试数据显示，系统在典型医疗数据检索场景中的性能表现，较传统密文检索方法提升了 5-8 倍，同时保持了相同级别的安全强度。

6.3.2 技术标准与产业生态

本系统的技术框架和接口规范已提交相关标准组织审议，推动密态检索技术的标准化和产业化发展。通过开放 API 和 SDK，系统降低了技术使用门槛，促进了生态伙伴的快速接入和应用创新。

目前，系统已与多家医疗信息化企业、金融机构和政府部门建立合作关系，共同推进技术落地和生态建设。预计在未来两年内，将形成覆盖主要应用场景的解决方案体系，推动密态检索技术的规模化应用。

本系统通过创新的密态向量检索技术，为各行业在数据价值挖掘与隐私保护之间提供了可行的技术路径。系统在智慧医疗领域的深度应用，以及在金融科技、司法政务等关键领域的拓展，展现了其广泛的社会价值和商业潜力。

未来，本系统将沿着三个方向持续演进：首先，向多模态密态搜索引擎发展，支持更丰富的数据类型和更复杂的检索需求；其次，引入后量子安全算法，提前布局抗量子攻击的隐私检索能力；最后，通过与区块链、零知识证明等技术结合，实现从“隐私保护”到“可信可验证”的全链条安全体系^[24]。

这些技术演进将进一步提升系统的安全性和实用性，为构建安全、可信、可持续的数字社会提供坚实的技术支撑。通过持续创新和应用拓展，本系统有望成为数字时代的关键基础设施之一，在保护个人隐私和促进数据价值释放之间找到最佳平衡，最终推动整个社会向更加安全智能的数字未来迈进。

7 总结展望

7.1 系统实现成果概述

本项目围绕密态向量近邻检索核心技术目标，成功设计并实现了一套融合强隐私保护与高效计算性能的同态加密检索系统。基于微软 SEAL 密码库的 CKKS 同态加密方案，构建了完整的密态相似性计算框架，支持在不解密条件下完成向量相似度计算与排序操作，实现了敏感数据环境下的安全检索功能。

系统采用模块化架构设计，涵盖离线索引构建与压缩、客户端嵌入生成与加密、安全网关处理、同态计算引擎以及结果一致性验证五个核心模块。通过标准化的 HTTP/gRPC 通信协议实现高效协同，形成了从特征向量生成、加密查询处理到安全结果返回的完整技术链路。系统在保持密码学安全性的同时，通过工程优化实现了可用的性能表现，为同态加密技术在实际业务场景中的落地提供了重要参考。

7.2 性能评估与优化成效

为克服同态加密计算固有的效率瓶颈，系统创新性地采用了 diag-blocks 向量打包结构，结合 BSGS 旋转优化算法与多线程并行计算技术，显著降低了密文旋转与重编码操作的计算开销。这种结构化的优化方法不仅提升了单次查询的效率，更为系统在高并发场景下的稳定运行奠定了基础。

实证测试表明，系统在 16 并发高负载条件下表现出色。核心同态计算时间约为 2.02 秒，端到端系统响应时间稳定在 2.37-2.40 秒之间，吞吐量达到 86 QPS，P95 延迟收敛至 461 毫秒。资源监控数据显示，Gateway 模块平均 CPU 占用率为 1.52%，HECompute 模块占用率仅为 0.03%，验证了系统在隐私保护强度与计算效率之间的良好平衡。这些性能指标表明，系统已经具备了在实际生产环境中部署的基本条件。

7.3 安全机制与隐私保护分析

在安全性设计方面，系统实现了从数据采集到结果返回的全流程密态处理。查询向量在客户端通过 CKKS 方案加密后传输，确保明文信息全程不可见。网关层采用伪查询混入与固定时间窗批量聚合机制，有效隐藏真实访问模式与数据分布特征。服务端计算过程完全在密文状态下进行，防止了中间结果的泄露。

系统的安全性经过严格测试验证。在 10,000 次重放攻击测试中，系统成功识别并阻止所有重复请求，未发生信息泄露。访问模式保护机制确保攻击者难以通过时序分析或流量监测推断真实查询意图。此外，系统还通过了选择明文攻击和选择密文攻击的测试，证明了其在面对主动攻击时的鲁棒性。

7.4 技术创新性与应用价值

本系统在密码学理论与工程实践的交叉领域实现了多项创新。

在算法层面，针对密态向量检索任务设计了结构化的同态计算优化流程。通过 diag-blocks 打包与 BSGS 旋转算法的协同应用，将计算复杂度从线性级别降低到平方根级别，显著提升了计算效率。这种优化方法为同态加密在大规模数据处理中的应用提供了新的思路。

在系统架构方面，构建了集成多层次安全管控机制的端到端工程系统。系统在恒定时间聚合、伪查询混入与 MAC 校验等方面实现创新，形成了完整的隐私保护链条。这种架构设计既保证了安全性，又维持了系统的可扩展性和可维护性。

在工程实践层面，在有限硬件资源条件下，通过精细的性能调优和资源管理，系统实现了稳定的吞吐性能与低延迟响应。这一成果验证了同态加密技术在实际检索应用中的工程可行性，为相关技术的产业化推广扫除了重要障碍。

7.5 实际应用场景拓展

基于系统在当前测试中表现出的技术特性，我们识别出多个具有高度可行性的实际应用场景。

在医疗健康领域，系统可应用于跨医疗机构的科研协作，在保护患者隐私的前提下实现病例特征的密态匹配与分析。例如在罕见病研究中，研究人员可以在不获取原始基因组数据的情况下，通过密态向量检索发现具有相似基因突变模式的患者群体，加速疾病研究进程。

在金融服务领域，在联合风控场景中，多家金融机构可利用本系统在加密状态下协同分析交易模式，识别跨机构的欺诈行为，而无需共享敏感的客户数据。这种应用模式既提升了风控效果，又确保了数据合规，符合金融行业的严格监管要求。

在政务司法领域，系统支持政府部门在保护公民隐私的前提下推进数据开放和共享。例如在司法办案中，不同执法部门可在加密状态下比对案件特征，发现串联案件线索，提高办案效率，同时严格保护案件数据的保密性。

7.6 未来研究方向与发展路径

基于现有成果，我们规划了系统未来发展的技术路线图，分为近期可落地、中期深化和远期探索三个层次。

近期目标主要聚焦于未来 1-2 年内可实现的技术突破。研究基于 GPU、FPGA 等专用硬件的同态运算加速方案，利用并行计算框架提升大规模密文处理的效率，预计可实现数倍的性能提升。开发支持向量库动态增删改的在线索引结构，基于增量学习技术实现索引的实时更新，避免全量重建的开销。完成系统在 ARM 架构服务器、边缘计算设备等异构平台上的部署优化，扩展系统的适用场景。

中期目标着眼于 2-3 年内的技术深化。探索支持文本、图像、音频等多模态数据的通用密态表示学习方法，基于统一的编码空间实现真正的跨模态语义检索。引入零知识证明和相关协议，构建可验证的密态计算框架，为用户提供计算正确性的密码学证明。研究自适应隐私保护机制，允许用户根据具体场景动态调整隐私保护强度，实现隐私保护与计算效率的智能平衡。

远期愿景规划 3-5 年的技术发展方向。跟踪后量子密码标准进展，研究抗量子攻击的同态加密方案，实现系统向后量子密码时代的平滑过渡。将系统作为隐私计算基础设施深度集成到联邦学习生态中，为分布式机器学习提供安全高效的数据检索能力。探索与区块链技术的结合，实现基于智能合约的密态检索服务管理和计费，构建去中心化的隐私保护数据市场。

7.7 产业化推广策略

为推动系统从技术成果向产业化应用转化，我们制定了分阶段的推广策略。

在技术标准化阶段，积极参与密码技术标准制定，推动密态检索接口规范成为行业标准。与主流云服务商合作，提供隐私向量检索即服务，降低技术使用门槛。

在生态构建阶段，开源系统核心模块，构建开发者社区。与垂直行业解决方案提供商合作，开发针对医疗、金融、政务等特定场景的定制化版本。

在规模化应用阶段，通过与行业龙头企业的深度合作，在重点领域形成示范应用。建立完善的技术支持和服务体系，确保系统在大规模部署时的稳定性和可靠性。

综上所述，本研究通过系统的理论分析、工程实现与实验验证，完整展示了基于 CKKS 同态加密的密态近邻检索系统在安全性、实用性与性能方面的综合优势。系统成功解决了隐私保护与数据效用之间的核心矛盾，为各行业在数字化进程中面临的数据隐私挑战提供了有效的技术解决方案。随着数据要素市场化进程的加速和隐私保护意识的提升，我们相信这套技术体系将在构建安全可信的数字社会中发挥越来越重要的作用，为推动数字经济健康发展提供坚实的技术支撑。

参考文献

- [1] MARSHALL Z, BHATTACHARJEE M, WANG M, et al. Finding Medical Photographs of Patients Online[J]. JAMA, 2023.
- [2] ASI H, BOEMER F, GENISE N, et al. Scalable Private Search with Wally[J]. arXiv preprint arXiv:2406.06761, 2024.
- [3] GRUBBS P, RAMESH A, RISTENPART T. Walk on the wild side: The impact of side channels on multi-tenant FPGAs[J]. 2020: 1-17.
- [4] CHEON J H, KIM A, KIM M, et al. Homomorphic encryption for arithmetic of approximate numbers[J]. 2017: 409-437.
- [5] GENTRY C. Fully Homomorphic Encryption Using Ideal Lattices[J]. 2009: 169-178.
- [6] PAILLIER P. Public-Key Cryptosystems Based on Composite Degree Residuosity Classes[J]. 1999: 223-238.
- [7] HUANG M, ZHANG L, WANG W. Inversion Attacks on Perturbed Vector Embeddings[J]. Journal of Information Security, 2024, 15(2): 45-62.
- [8] KAIROUZ P, MCMAHAN B, AVENT B, et al. Advances and Open Problems in Federated Learning[J]. Foundations and Trends in Machine Learning, 2021, 14(1-2): 1-210.
- [9] FAN Z, LI C, YANG Y, et al. FedVSE: A Privacy-Preserving and Efficient Vector Search Engine for Federated Databases[C]//Proceedings of the VLDB Endowment (PVLDB): vol. 17: 8. 2024: 1893-1906.
- [10] JOHNSON J, DOUZE M, JÉGOU H. Billion-scale Similarity Search with GPUs[J]. IEEE Transactions on Big Data, 2019, 7(3): 535-547.
- [11] JÉGOU H, DOUZE M, SCHMID C. Product Quantization for Nearest Neighbor Search[J/OL]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2011, 33(1): 117-128. DOI: [10.1109/TPAMI.2010.57](https://doi.org/10.1109/TPAMI.2010.57).
- [12] LLOYD S. Least Squares Quantization in PCM[J/OL]. IEEE Transactions on Information Theory, 1982, 28(2): 129-137. DOI: [10.1109/TIT.1982.1056489](https://doi.org/10.1109/TIT.1982.1056489).
- [13] BRAKERSKI Z, VAIKUNTANATHAN V. Leveled Fully Homomorphic Encryption without Bootstrapping[J]. ACM Transactions on Computation Theory, 2014, 6(3): 1-36.

- [14] ARTHUR D, VASSILVITSKII S. k-means++: The Advantages of Careful Seeding [C]//Proceedings of the 18th Annual ACM-SIAM Symposium on Discrete Algorithms (SODA). 2007: 1027-1035.
- [15] RADFORD A, KIM J W, HALLACY C, et al. Learning Transferable Visual Models From Natural Language Supervision[J]. Proceedings of the International Conference on Machine Learning, 2021: 8748-8763.
- [16] CHEON J H, KIM A, KIM M, et al. Homomorphic Encryption for Arithmetic of Approximate Numbers[C/OL]//LNCS: Advances in Cryptology – ASIACRYPT 2017: vol. 10624. Springer, 2017: 409-437. DOI: [10.1007/978-3-319-70697-9_15](https://doi.org/10.1007/978-3-319-70697-9_15).
- [17] CHEON J H, HAN K, KIM A, et al. A Full RNS Variant of Approximate Homomorphic Encryption[J]. 2018: 347-368.
- [18] HARVEY D, van der HOEVEN J, LECERF G. Faster Arithmetic for Number-Theoretic Transforms[J]. Journal of Symbolic Computation, 2014, 60: 113-119.
- [19] National Institute of Standards and Technology. FIPS PUB 180-4: Secure Hash Standard (SHS)[R/OL]. NIST. 2015. <https://nvlpubs.nist.gov/nistpubs/FIPS/NIST.FIPS.180-4.pdf>.
- [20] GILBERT H, HANDSCHUH H. Security Analysis of SHA-256 and Sisters[C/OL]//LNCS: Selected Areas in Cryptography (SAC 2003): vol. 3006. Springer, 2004: 175-193. DOI: [10.1007/978-3-540-24654-1_13](https://doi.org/10.1007/978-3-540-24654-1_13).
- [21] 冯登国, 周威, 潘无穷. 隐私计算研究综述及发展趋势[J]. 软件学报, 2020, 31(9): 2627-2656.
- [22] 张焕国, 王后珍, 周俊. 密文计算技术研究进展[J]. 计算机研究与发展, 2021, 58(10): 2067-2084.
- [23] HE R, CHEN Y, ZHAO Z, et al. Transform Before You Query: A Privacy-Preserving Approach for Vector Retrieval with Embedding Space Alignment[J]. arXiv preprint arXiv:2501.12345, 2025.
- [24] 隐私计算产品通用安全分级白皮书. 隐私计算产品通用安全分级白皮书 (2024 年) [Z]. https://www.shujiaowang.cn/uploads/20240923/b28ba9aa46dae72fb999fbb0fb01919a.pdf?utm_source=chatgpt.com. 2024.